目录

前言 4
1 多源轴承故障数据的预处理 6
1.1 导入数据 6
2.2 数据集预处理 7
2 以 VGG 故障分类模型为例 8
2.1 设置参数，训练模型 8
2.2 模型评估 10
3 代码、数据整理如下： 14

多源信息融合+经典卷积网络故障诊断模型合集

目录

1. 往期精彩内容：
2. 前言
3. 1 多源轴承故障数据的预处理
    a. 1.1 导入数据
    b. 2.2 数据集预处理
4. 2 以 VGG 故障分类模型为例
    a. 2.1 设置参数，训练模型
    b. 2.2 模型评估
5. 3 代码、数据整理如下：

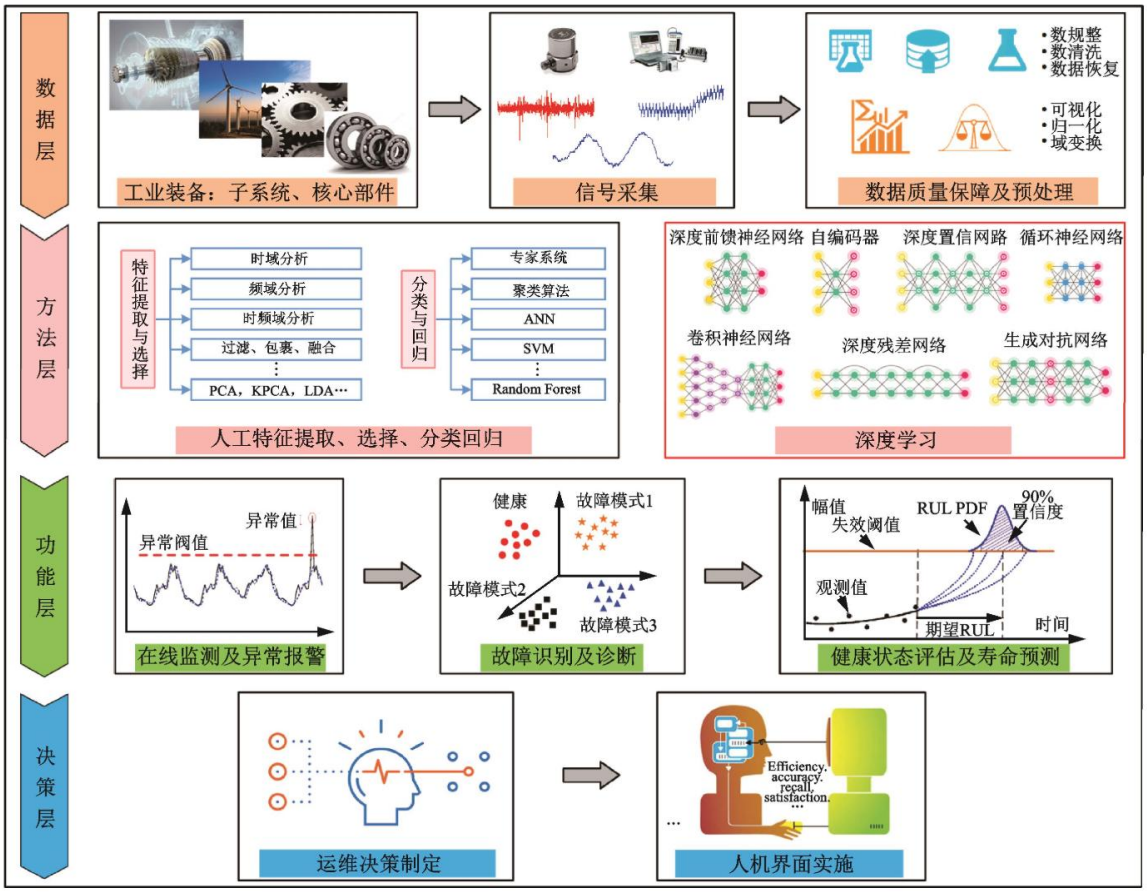

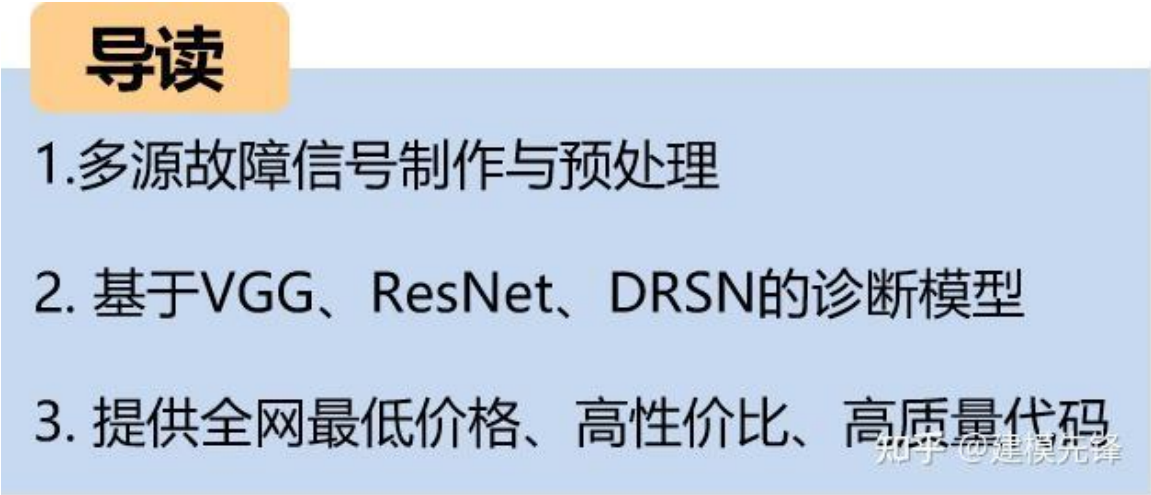

往期精彩内容：

Python-凯斯西储大学（CWRU）轴承数据解读与分类处理 - 知乎 (zhihu.com)

基于 FFT + CNN - BiGRU-Attention 时域、频域特征注意力融合的轴承故障识别模型 - 知乎 (zhihu.com)

基于 FFT + CNN - Transformer 时域、频域特征融合的轴承故障识别模型 - 知乎 (zhihu.com)

交叉注意力融合时域、频域特征的 FFT + CNN -BiLSTM-CrossAttention 轴承故障识别模型 - 知乎 (zhihu.com)

Python 轴承故障诊断 (13)基于故障信号特征提取的超强机器学习识别模型 - 知乎 (zhihu.com)

建模先锋：Python 轴承故障诊断 (14)高创新故障识别模型

独家原创 | SCI 1 区 高创新轴承故障诊断模型！ - 知乎 (zhihu.com)

建模先锋：Python 轴承故障诊断 (19)基于 Transformer-BiLSTM 的创新诊断模型

基于 k-NN + GCN 的轴承故障诊断模型 - 知乎 (zhihu.com)

独家首发 | 基于 KAN、KAN 卷积的轴承故障诊断模型 - 知乎 (zhihu.com)

SHAP 模型可视化 + 参数搜索策略在轴承故障诊断中的应用 - 知乎 (zhihu.com)

建模先锋：独家原创 | 基于 2D-SWinTransformer + 1D-CNN-SENet 并行故障诊断模型

建模先锋：时频图像分类，还在用 VGG、ResNet?

建模先锋：详解 Transformer 中位置编码 Positional Encoding

建模先锋：Python 轴承故障诊断 (20)高创新故障识别模型（三）

建模先锋：Python 轴承故障诊断 (21)基于 VMD-CNN-BiTCN 的创新诊断模型

建模先锋：三十多个开源数据集 | 故障诊断再也不用担心数据集了！

建模先锋：独家首发 | 基于 2D-SWinTransformer + BiGRU-GlobalAttention 的并行故障诊断模型

建模先锋：资源分享 | 基于图神经网络的智能故障诊断和预测

建模先锋：代码开源！ | 变工况下的域对抗图卷积网络故障诊断

建模先锋：重磅！轴承寿命预测全家桶来了！

建模先锋：智能故障诊断和寿命预测期刊推荐

建模先锋：超强！一区直接写！基于 SSA+Informer-SENet 故障诊断模型

建模先锋：故障诊断 | 信号降噪算法合集

建模先锋：图卷积故障诊断，新增 GAT、SGCN、GIN 分类模型

建模先锋：故障诊断一区直接写，图卷积+BiGRU-Attention 并行诊断模型

建模先锋：故障诊断高创新！基于 1D-GRU+2D-MTF-ResNet-CBAM 的多模态融合分类模型

建模先锋：故障诊断最强更新！基于 VMD+Transformer-BiGRU 的分类模型

建模先锋：创新首发！ | 基于 1DCNN-Informer+MATT 融合的 故障诊断模型

轴承寿命预测全家桶更新！新增西交 XJTU-SY 数据集+模型合集 - 知乎

江南大学轴承故障诊断教程+1DVGG-6 种注意力机制合集！ - 知乎

建模先锋：故障诊断独家创新！基于 GADF+SwinTransformer -CBAM+GRU 的多模态融合分类模型

建模先锋：故障诊断模型评估——混淆矩阵，如何使样本量一致（上）

建模先锋：故障诊断模型评估——混淆矩阵，如何使样本量一致（下）

建模先锋：重大更新！基于 VMD+Transformer-BiLSTM-CrossAttention 故障分类模型

前言

进行多源信号数据的故障诊断涉及多个步骤，包括数据预处理、特征提取、模型应用和性能评估。

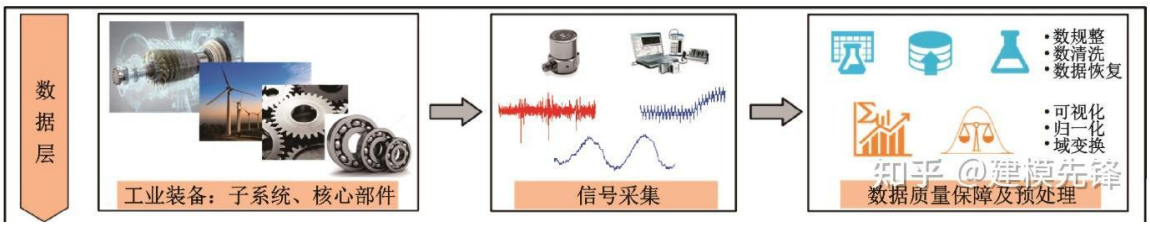

本期基于东南大学轴承故障数据集（8 个通道信号），进行多源信号数据的预处理讲解，并搭配经典卷积网络 VGG、ResNet、深度残差收缩网络 DRSN 进行故障诊断的完整代码合集。（适合多传感器、多特征列的信号分类任务）

多源信息融合的滚动轴承故障诊断是一种结合来自多个传感器或信号源的信息，以提高故障检测和诊断准确性的方法。

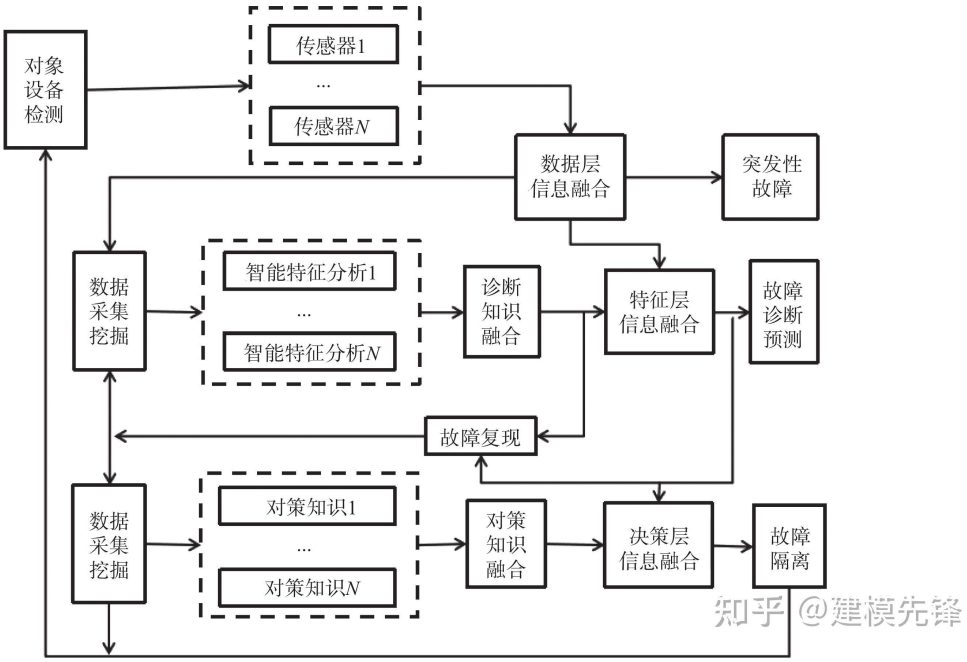

多源信息融合的优势：

- 提高诊断准确性：单一信号源可能无法提供足够的信息来准确诊断复杂的故障模式。通过融合多个信号源的信息，可以更全面地了解系统的状态。
- 增强鲁棒性：不同信号源对不同类型的噪声和干扰有不同的敏感性。通过融合，可以减小某个信号源的局限性对整体诊断性能的影响。
- 检测多种故障类型：不同的信号源可能对不同类型的故障敏感。例如，振动信号可以很好地检测滚动轴承的机械故障，而声学信号可能更适合检测早期故障。

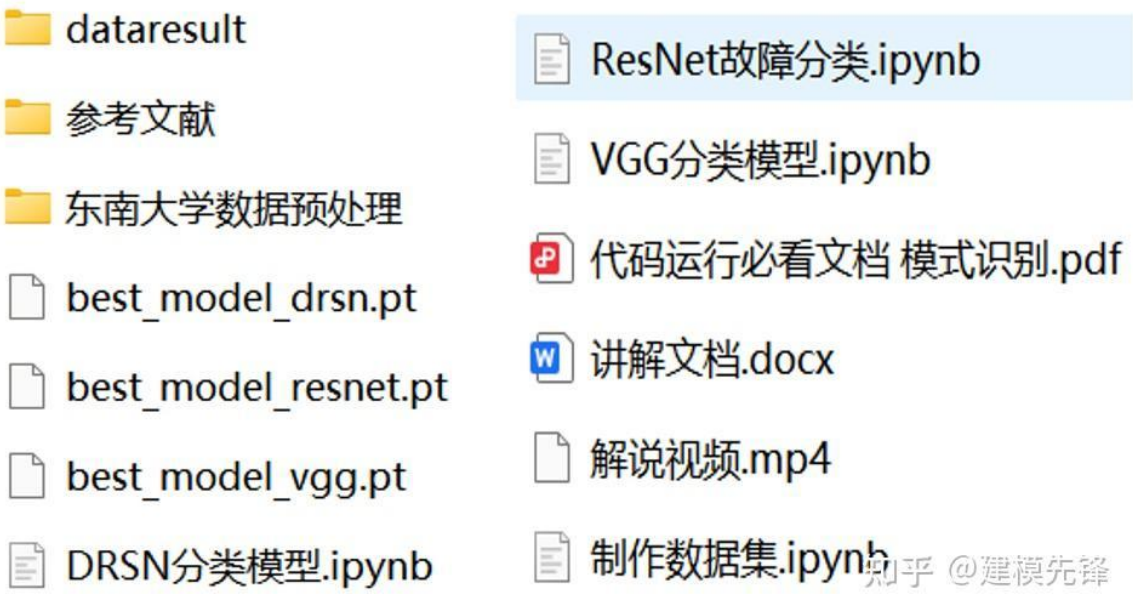

- 数据集：东南大学轴承故障数据集
- 环境框架：python 3.9 pytorch 2.1 及其以上版本均可运行

● 准确率：测试集 99%
● 使用对象：论文需求、毕业设计需求者
● 代码保证：代码注释详细、即拿即可跑通。

1 多源轴承故障数据的预处理

1.1 导入数据

东南大学数据集主要分为轴承数据集和齿轮箱数据集，每个故障类型均对应这个两种工况（转速 20Hz（1200rpm）-负载 0V(0Nm) 和转速 30Hz(1800rpm)-负载 2V(7.32Nm)）分别对应着 gearset 和 bearingset 文件夹。轴承数据集（5 种类型）：

- 滚珠故障（Ball fault）
- 内圈故障（Inner ring fault）
- 外圈故障（Outer ring fault）
- 复合故障（Combination fault on both inner ring and outer ring）
- 正常运行（Health woring state）

我们以 5 分类轴承数据集进行预处理讲解

```python
import pandas as pd
# 1.读取数据
data_file_csv1 = './dataresult/inner_20_0_new.csv'
data_file_csv2 = './dataresult/ball_20_0_new.csv'
data_file_csv3 = './dataresult/outer_20_0_new.csv'
data_file_csv4 = './dataresult/comb_20_0_new.csv'
data_file_csv5 = './dataresult/health_20_0_new.csv'
origin_data1 = pd.read_csv(data_file_csv1)
origin_data2 = pd.read_csv(data_file_csv2)
origin_data3 = pd.read_csv(data_file_csv3)
origin_data4 = pd.read_csv(data_file_csv4)
origin_data5 = pd.read_csv(data_file_csv5)

print(origin_data1.shape)
print(origin_data2.shape)
print(origin_data3.shape)
print(origin_data4.shape)
print(origin_data5.shape)
origin_data1.head()
```

✓ 4.8s

```
(1048560, 8)
(1048560, 8)
(1048560, 8)
(1048560, 8)
(1048560, 8)
```

	Column1	Column2	Column3	Column4	Column5	Column6	Column7	Column8
0	-0.117462	-0.001712	0.001460	0.007768	0.002619	0.003544	0.003097	-0.007119
1	-0.122317	-0.000914	-0.004050	-0.006717	0.003122	-0.012211	0.005323	-0.002731
2	-0.121311	0.004437	0.003101	0.007753	0.006050	0.003830	-0.007553	0.008774
3	-0.120751	-0.007136	-0.002774	0.002573	0.006198	0.001988	-0.001854	0.002958
4	-0.117236	-0.000008	0.000765	-0.007696	0.002301	0.004705	[illegible]	[illegible]

知乎 @建模先锋

数据集为 8 通道！

2.2 数据集预处理

根据前两期数据集样本的讲解教程：
故障诊断模型评估——混淆矩阵，如何使样本量一致（上）

故障诊断模型评估——你了解混淆矩阵吗？（下）

现在把设置样本的两个参数固定：

- 样本窗口大小：W = 1024
- 重叠率：overlap = 0.5

```
[数据维度] 原始数据: (10000, 1024, 8)
[样本分布] 总样本数: 10000
训练集: 7000 (70.0%)
验证集: 2000 (20.0%)
测试集: 1000 (10.0%)
```

知乎 @建模先锋

通过滑动窗口制作数据集，并按照 7：2：1 均匀划分训练集、验证集、测试集，最后保存数据，划分完成的数据集分布情况如下：

```
[原始数据类别分布]
类别 0: 2000 (20.0%)
类别 1: 2000 (20.0%)
类别 2: 2000 (20.0%)
类别 3: 2000 (20.0%)
类别 4: 2000 (20.0%)
```

```
[训练集类别分布]
类别 0: 1400 (20.0%)
类别 1: 1400 (20.0%)
类别 2: 1400 (20.0%)
类别 3: 1400 (20.0%)
类别 4: 1400 (20.0%)
```

```
[验证集类别分布]
类别 0: 400 (20.0%)
类别 1: 400 (20.0%)
类别 2: 400 (20.0%)
类别 3: 400 (20.0%)
类别 4: 400 (20.0%)
```

```
[测试集类别分布]
类别 0: 200 (20.0%)
类别 1: 200 (20.0%)
类别 2: 200 (20.0%)
类别 3: 200 (20.0%)
类别 4: 200 (20.0%)
```

知乎 @建模先锋

2 以 VGG 故障分类模型为例

2.1 设置参数，训练模型

```
Train Loss: 0.0346 Acc: 0.9879 | Val Loss: 0.0344 Acc: 0.9845
----------
Epoch 47/50
Train Loss: 0.0314 Acc: 0.9884 | Val Loss: 0.0304 Acc: 0.9870
----------
Epoch 48/50
Train Loss: 0.0286 Acc: 0.9903 | Val Loss: 0.0296 Acc: 0.9895
----------
Epoch 49/50
Train Loss: 0.0303 Acc: 0.9887 | Val Loss: 0.0455 Acc: 0.9860
----------
Epoch 50/50
Train Loss: 0.0357 Acc: 0.9881 | Val Loss: 0.0251 Acc: 0.9925
----------

Duration: 51 seconds
```

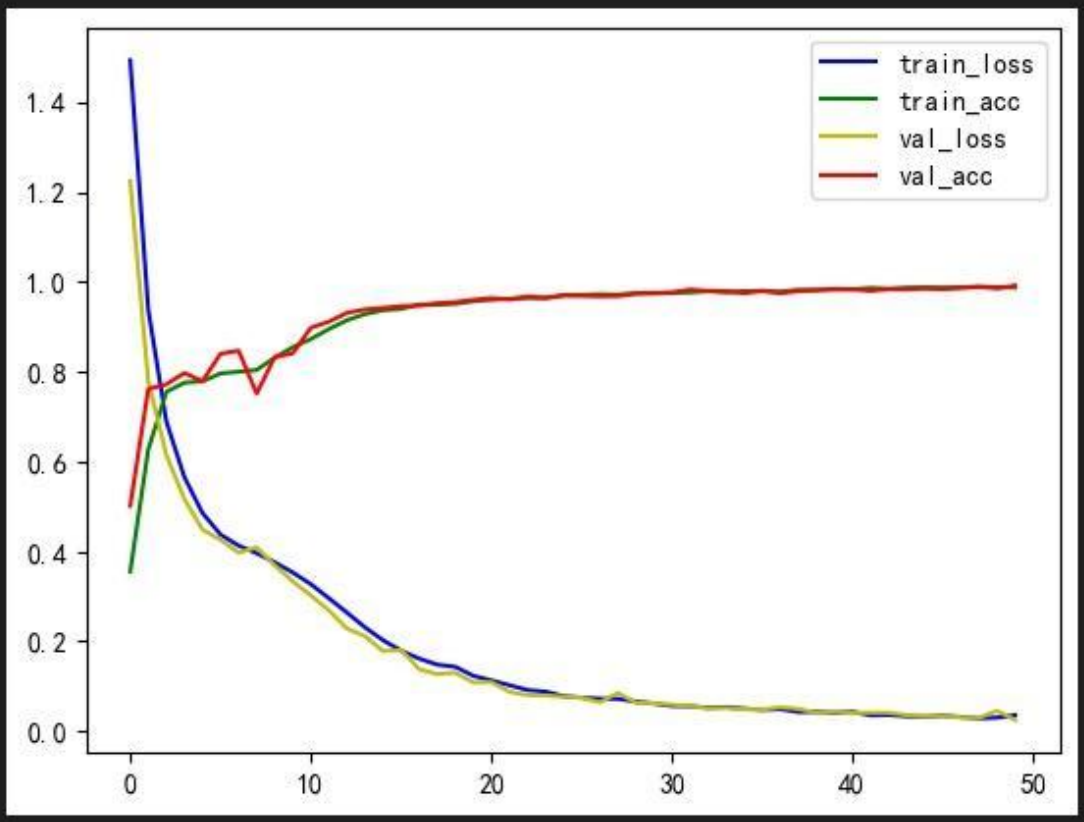

知乎 @建模先锋

```
best_accuracy : 0.9925
```

50 个 epoch，准确率 99%，用 VGG 网络分类效果显著，能够从多源故障信号特征中提取出对模型识别重要的特征，效果明显!

2.2 模型评估

（1）准确率、精确率、召回率、F1 Score

	precision	recall	f1-score	support
0	1.0000	1.0000	1.0000	200
1	1.0000	1.0000	1.0000	200
2	1.0000	1.0000	1.0000	200
3	1.0000	0.9900	0.9950	200
4	0.9901	1.0000	0.9950	200
accuracy			0.9980	1000
macro avg	0.9980	0.9980	0.9980	1000
weighted avg	0.9980	0.9980	0.9980	1000

知乎 @建模先锋

（2）故障 5 分类混淆矩阵：

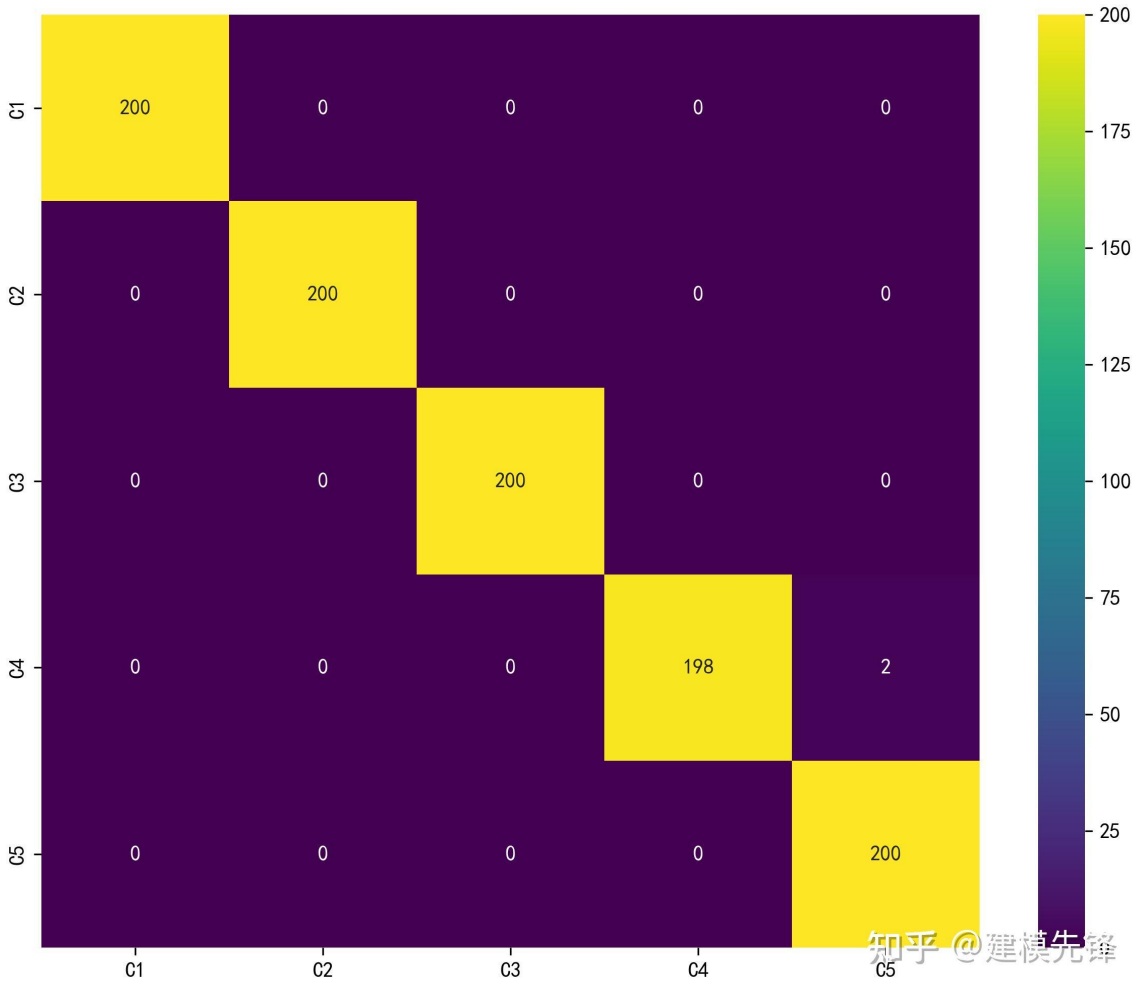

知乎 @建模先锋

（3）分类标签可视化

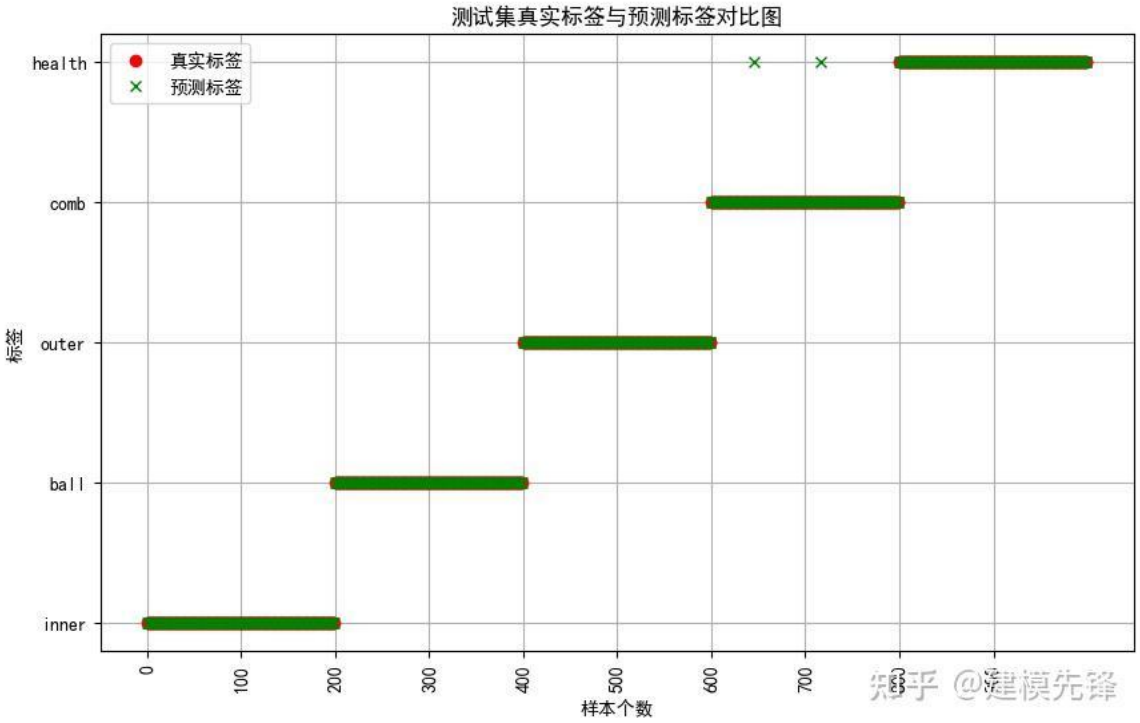

（4）原始数据 t-SNE 特征可视化

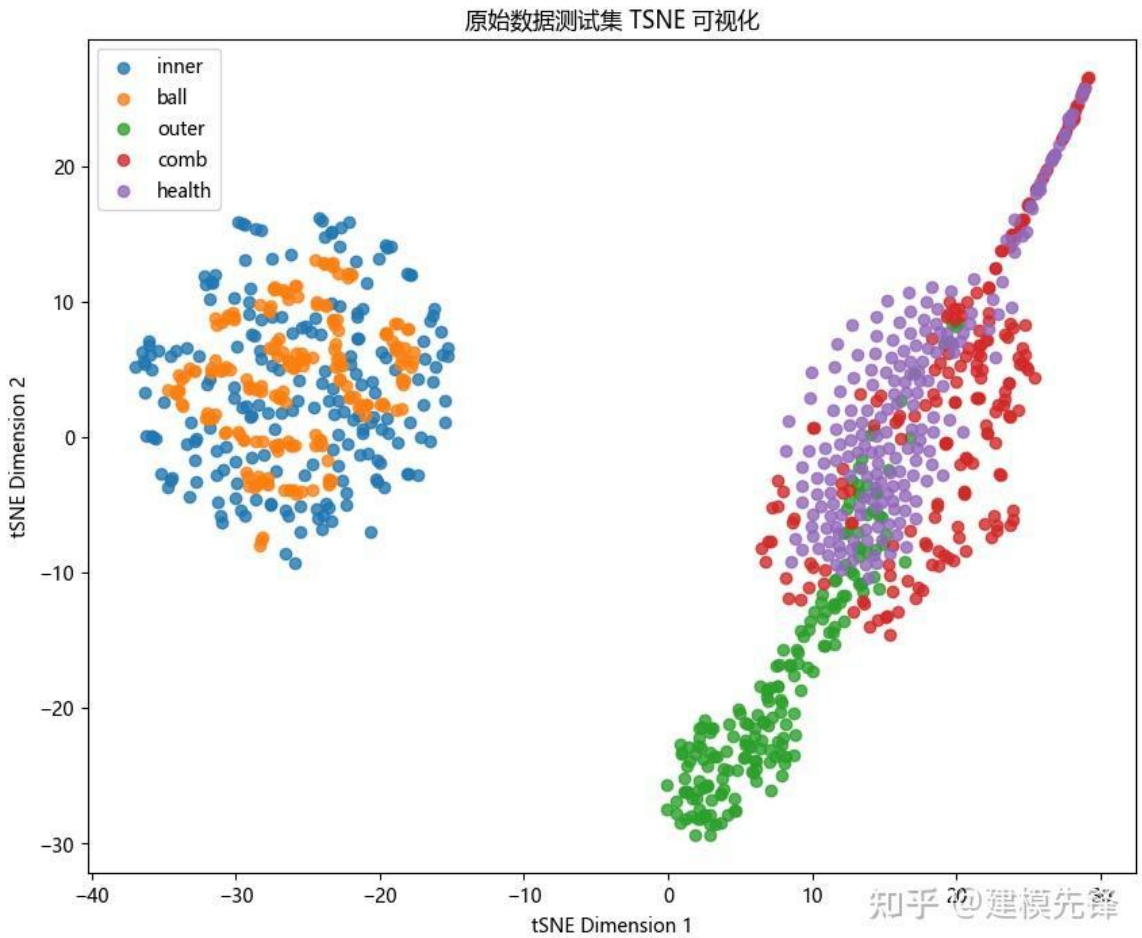

（5）模型训练后的 t-SNE 特征可视化：

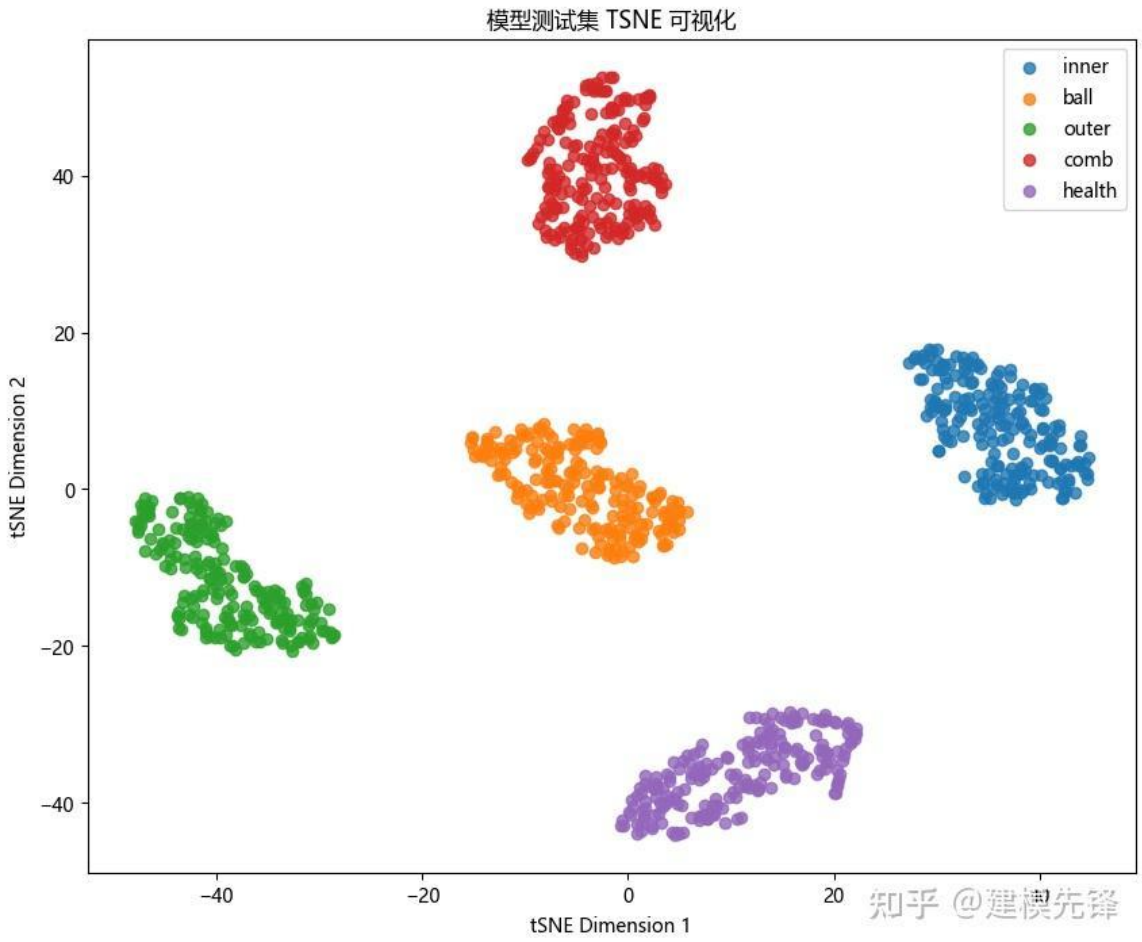

3 代码、数据整理如下：

相关数据集预处理、文件说明、模型代码如下：

- dataresult
- 参考文献
- 东南大学数据预处理
- best_model_drsn.pt
- best_model_resnet.pt
- best_model_vgg.pt
- DRSN分类模型.ipynb
- ResNet故障分类.ipynb
- VGG分类模型.ipynb
- 代码运行必看文档 模式识别.pdf
- 讲解文档.docx
- 解说视频.mp4
- 制作数据集.ipynb

知乎 @建模先锋