(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 120611266 A
(43)申请公布日 2025.09.09

(21)申请号 202510649734.0

(22)申请日 2025.05.20

(71)申请人 中铁第四勘察设计院集团有限公司
地址 430063 湖北省武汉市武昌区和平大道745号

(72)发明人 张鹏 邵靖男 孙敬伟 耿明 邱绍峰 何杰 李成洋 罗小华 张银龙 刘梦琪 李加祺 冯海旭 刘辉 张俊岭 彭方进

(74)专利代理机构 武汉科皓知识产权代理事务所(特殊普通合伙) 42222
专利代理师 彭艳君

(51)Int.Cl.
G06F 18/2415(2023.01)
G06F 18/20(2023.01)
G06F 18/25(2023.01)
G08B 31/00(2006.01)
G08B 21/18(2006.01)
G06N 3/042(2023.01)
G06N 3/045(2023.01)
G06N 3/0442(2023.01)
G06F 18/213(2023.01)
G06Q 10/10(2023.01)
G06Q 10/20(2023.01)

权利要求书2页 说明书9页 附图1页

(54)发明名称

一种多源数据融合的关键部件故障预测方法及系统

(57)摘要

本发明提供一种多源数据融合的关键部件故障预测方法及系统,所述方法包括:S1、采集清筛机关键部件数据,构建多源异构传感网络,完成多维度监测数据的时空对齐与质量优化;S2、基于部件物理连接关系构建动态拓扑图结构,量化故障传播路径与强度,形成涵盖局部状态与整体健康度的多层次特征表征;S3、设计融合时空分析与记忆建模的混合预测模型,通过自适应的特征整合机制,完成对设备退化趋势的准确刻画与潜在故障的早期预警;S4、结合实时预测误差与历史运维知识动态优化混合预测模型,建立数据驱动与知识引导的双重学习框架,完成随设备老化自适应的持续学习。本发明方法突破了传统预测模型静态化的局限,显著提升了预测结果的准确性和可靠性。

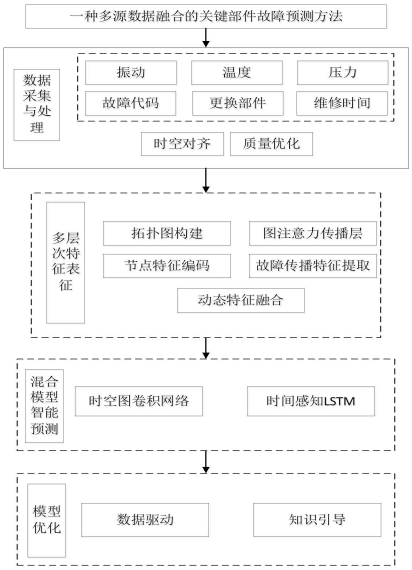

CN 120611266 A

1.一种多源数据融合的关键部件故障预测方法,其特征在于,包括以下步骤:

S1、利用多源传感器采集清筛机关键部件数据,构建多源异构传感网络,通过预处理构建分析数据集,通过信号处理完成多维度监测数据的时空对齐与质量优化;

S2、基于部件物理连接关系构建动态拓扑图结构,运用图神经网络量化故障传播路径与强度,形成涵盖局部状态与整体健康度的多层次特征表征,并动态调整融合权重;

S3、设计融合时空分析与记忆建模的混合预测模型,通过自适应的特征整合机制,完成对设备退化趋势的准确刻画与潜在故障的早期预警;

S4、结合实时预测误差与历史运维知识动态优化混合预测模型,建立数据驱动与知识引导的自学习系统,并完成混合预测模型的持续优化。

2.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法,其特征在于,所述清筛机关键部件包括振动筛箱、激振器、输送带驱动装置;所述利用多源传感器采集清筛机关键部件数据包括:振动、温度和油液数据;所述预处理包括:数据清洗、去噪及格式标准化处理。

3.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法,其特征在于,所述信号处理包括:变分模态分解去噪和小波变换;通过信号处理完成多维度监测数据的时空对齐包括:

时间同步:采用精密时钟协议,统一振动、温度、油液传感器的采样时间戳,消除因硬件延迟或采样率差异导致的数据时间错位;

空间对齐:基于部件物理位置,建立传感器数据的空间映射关系,确保故障信号能关联到具体部件。

4.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法,其特征在于,通过信号处理完成多维度监测数据的质量优化包括:

工况自适应去噪:针对振动信号,使用变分模态分解动态调整模态参数,分离噪声与故障特征;对温度数据,通过滑动窗口Z-score标准化消除环境干扰;

多模态特征增强:结合时域、频域、时频域特征,通过韦伯分布建模油液颗粒数据,提升故障敏感度。

5.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法,其特征在于,所述基于部件物理连接关系构建动态拓扑图结构,运用图神经网络量化故障传播路径与强度,形成涵盖局部状态与整体健康度的多层次特征表征,并动态调整融合权重包括:

基于设备物理连接关系构建拓扑图结构,将关键部件转化为图节点,部件间的动力传递路径转化为有向连接边;

设计多维节点特征编码机制,每个节点特征包含时频域特征、工况参数和空间位置信息数据;

采用多头注意力机制实现特征交互,设计多组独立的注意力计算单元,每组关注不同的故障传播模式,各单元通过可训练参数计算节点间的注意力权重,动态捕捉关键故障路径;

故障传播特征提取采用多层处理架构,先通过三层图卷积网络提取高阶节点特征,再分别计算全局特征、路径特征和时序特征;所述全局特征用来捕捉系统整体状态,所述路径特征用来分析历史故障传播规律,所述时序特征用来跟踪目标部件的退化轨迹,三类特征

组合形成完整的系统状态表征；

设计智能特征融合机制，通过门控神经网络自动评估局部特征和系统特征的贡献度，动态调整融合权重。

6.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法，其特征在于，所述设计融合时空分析与记忆建模的混合预测架构包括：

通过动态邻接矩阵实时量化部件间的故障传播强度，捕捉故障在设备系统中的空间扩散规律；引入衰减因子强化近期故障特征的记忆权重；通过节点、时间、模态的三重注意力机制自适应融合多维特征，当融合后的异常概率超过动态阈值时触发预警。

7.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法，其特征在于，所述结合实时预测误差与历史运维知识动态优化混合预测模型，建立数据驱动与知识引导的自学习系统包括：

在数据驱动方面，建立动态修正机制，自动识别工况变化、新型故障和模型退化问题，并分别触发特征权重调整、小样本学习和知识蒸馏的自适应优化策略；

知识引导方面，构建了结构化的故障知识图谱，将专家经验和维修案例转化为可计算、可推理的数字化知识。

8.根据权利要求1所述的一种多源数据融合的关键部件故障预测方法，其特征在于，所述结合实时预测误差与历史运维知识动态优化混合预测模型包括：

通过实时监控预测误差，采用梯度分析动态评估特征重要性，并利用小样本学习快速适应新型故障模式，知识图谱通过语义网络存储故障特征与解决方案的关联关系，借助图神经网络实现知识检索和推理。

9.一种多源数据融合的关键部件故障预测系统，其特征在于，包括：

数据采集与处理模块，用于利用多源传感器采集清筛机关键部件数据，构建多源异构传感网络，通过预处理构建分析数据集，通过信号处理完成多维度监测数据的时空对齐与质量优化；

多层次特征表征模块，用于基于部件物理连接关系构建动态拓扑图结构，运用图神经网络量化故障传播路径与强度，形成涵盖局部状态与整体健康度的多层次特征表征，并动态调整融合权重；

混合模型智能预测模块，用于设计融合时空分析与记忆建模的混合预测模型，通过自适应的特征整合机制，完成对设备退化趋势的准确刻画与潜在故障的早期预警；

混合预测模型优化模块，结合实时预测误差与历史运维知识动态优化混合预测模型，建立数据驱动与知识引导的自学习系统，并完成混合预测模型的持续优化。

10.一种电子设备，其特征在于，包括存储器、处理器，所述处理器用于执行存储器中存储的计算机程序时实现如权利要求1-8任一项所述的一种多源数据融合的关键部件故障预测方法。

一种多源数据融合的关键部件故障预测方法及系统

技术领域

[0001] 本发明涉及机械设备状态监测和维护管理领域,更具体地,涉及一种多源数据融合的关键部件故障预测方法及系统。

背景技术

[0002] 当前清筛机关键部件的故障监测主要依靠定期人工巡检和简单的阈值报警系统。行业普遍采用基于振动幅值超限的简易诊断方法,通过设置固定阈值来判断设备状态。部分先进设备开始引入温度、压力等多参数监测,但各参数独立分析,缺乏综合评估机制。在预测技术方面,主要依赖设备厂商提供的经验寿命曲线,或基于运行时间的简单线性预测模型。近年来,一些研究尝试应用机器学习算法,但由于清筛机工作环境恶劣、工况复杂,实际应用效果有限。

[0003] 现有技术存在以下主要不足:首先,基于固定阈值的报警系统误报率高,无法识别早期潜在故障;其次,多参数监测数据缺乏有效融合方法,各参数间的关联性未被充分利用;再次,经验寿命曲线无法适应个体差异和实际工况变化,预测偏差大;最后,现有预测方法缺乏自学习能力,无法通过历史数据持续优化预测模型。这些问题导致现有系统在实际工程中预警准确率低、实用性差,难以为设备维护提供可靠决策支持。

发明内容

[0004] 本发明针对现有技术中存在的技术问题,提供一种多源数据融合的关键部件故障预测方法及系统,该方法显著提升了预测结果的准确性和可靠性,该系统突破了传统预测模型静态化的局限,实现了预测能力随使用时间的持续提升。

[0005] 根据本发明的第一方面,提供了一种多源数据融合的关键部件故障预测方法,包括以下步骤:

S1、利用多源传感器采集清筛机关键部件数据,构建多源异构传感网络,通过预处理构建分析数据集,通过信号处理完成多维度监测数据的时空对齐与质量优化;

S2、基于部件物理连接关系构建动态拓扑图结构,运用图神经网络量化故障传播路径与强度,形成涵盖局部状态与整体健康度的多层次特征表征,并动态调整融合权重;

S3、设计融合时空分析与记忆建模的混合预测模型,通过自适应的特征整合机制,完成对设备退化趋势的准确刻画与潜在故障的早期预警;

S4、结合实时预测误差与历史运维知识动态优化混合预测模型,建立数据驱动与知识引导的自学习系统,并完成混合预测模型的持续优化。

[0006] 在上述技术方案的基础上,本发明还可以作出如下改进。

[0007] 可选的,所述清筛机关键部件包括振动筛箱、激振器、输送带驱动装置;利用多源传感器采集清筛机关键部件数据包括:振动、温度、油液数据;所述预处理包括:数据清洗、去噪及格式标准化处理。

[0008] 可选的,所述信号处理包括:变分模态分解去噪和小波变换;通过信号处理完成多

维度监测数据的时空对齐包括：

时间同步：采用精密时钟协议，统一振动、温度、油液传感器的采样时间戳，消除因硬件延迟或采样率差异导致的数据时间错位；

空间对齐：基于部件物理位置，建立传感器数据的空间映射关系，确保故障信号能关联到具体部件。

[0009] 可选的，通过信号处理完成多维度监测数据的质量优化包括：

工况自适应去噪：针对振动信号，使用变分模态分解动态调整模态参数，分离噪声与故障特征；对温度数据，通过滑动窗口Z-score标准化消除环境干扰；

多模态特征增强：结合时域、频域、时频域特征，通过韦伯分布建模油液颗粒数据，提升故障敏感度。

[0010] 可选的，所述基于部件物理连接关系构建动态拓扑图结构，运用图神经网络量化故障传播路径与强度，形成涵盖局部状态与整体健康度的多层次特征表征，并动态调整融合权重包括：

基于设备物理连接关系构建拓扑图结构，将关键部件转化为图节点，部件间的动力传递路径转化为有向连接边；

设计多维节点特征编码机制，每个节点特征包含时频域特征、工况参数和空间位置信息数据；

采用多头注意力机制实现特征交互，设计多组独立的注意力计算单元，每组关注不同的故障传播模式，各单元通过可训练参数计算节点间的注意力权重，动态捕捉关键故障路径；

故障传播特征提取采用多层处理架构，先通过三层图卷积网络提取高阶节点特征，再分别计算全局特征、路径特征和时序特征；全局特征捕捉系统整体状态；路径特征分析历史故障传播规律；时序特征跟踪目标部件的退化轨迹。三类特征的组合形成完整的系统状态表征；

设计智能特征融合机制，通过门控神经网络自动评估局部特征和系统特征的贡献度，动态调整融合权重。

[0011] 可选的，所述设计融合时空分析与记忆建模的混合预测架构包括：

通过动态邻接矩阵实时量化部件间的故障传播强度，捕捉故障在设备系统中的空间扩散规律；引入衰减因子强化近期故障特征的记忆权重；通过节点、时间、模态的三重注意力机制自适应融合多维特征，当融合后的异常概率超过动态阈值时触发预警。

[0012] 可选的，所述结合实时预测误差与历史运维知识动态优化混合预测模型，建立数据驱动与知识引导的自学习系统包括：

在数据驱动方面，建立动态修正机制，自动识别工况变化、新型故障和模型退化问题，并分别触发特征权重调整、小样本学习和知识蒸馏的自适应优化策略；

知识引导方面，构建了结构化的故障知识图谱，将专家经验和维修案例转化为可计算、可推理的数字化知识。

[0013] 可选的，所述结合实时预测误差与历史运维知识动态优化混合预测模型包括：

通过实时监控预测误差，采用梯度分析动态评估特征重要性，并利用小样本学习快速适应新型故障模式，知识图谱通过语义网络存储故障特征与解决方案的关联关系，借

助图神经网络实现知识检索和推理。

[0014] 根据本发明的第二方面,提供一种多源数据融合的关键部件故障预测系统,包括:

数据采集与处理模块,用于利用多源传感器采集清筛机关键部件数据,构建多源异构传感网络,通过预处理构建分析数据集,通过信号处理完成多维度监测数据的时空对齐与质量优化;

多层次特征表征模块,用于基于部件物理连接关系构建动态拓扑图结构,运用图神经网络量化故障传播路径与强度,形成涵盖局部状态与整体健康度的多层次特征表征,并动态调整融合权重;

混合模型智能预测模块,用于设计融合时空分析与记忆建模的混合预测模型,通过自适应的特征整合机制,完成对设备退化趋势的准确刻画与潜在故障的早期预警;

混合预测模型优化模块,结合实时预测误差与历史运维知识动态优化混合预测模型,建立数据驱动与知识引导的自学习系统,并完成混合预测模型的持续优化。

[0015] 根据本发明的第三方面,提供了一种电子设备,包括存储器、处理器,所述处理器用于执行存储器中存储的计算机程序时实现一种多源数据融合的关键部件故障预测方法。

[0016] 本发明的技术效果和优点:

本发明提供一种多源数据融合的关键部件故障预测方法及系统,首先通过多源异构传感网络和信号处理技术实现了清筛机关键部件监测数据的精准采集与优化,其次采用时空对齐算法将振动、温度、油液多维度数据统一至同一时空基准,有效解决了复杂工况下的信号干扰问题;然后基于动态拓扑图结构和图学习技术,能够准确捕捉部件间的故障关联特性,实现从局部状态到整体健康度的多层次评估;最后融合时空分析与记忆建模的混合预测模型通过自适应特征整合,提升了设备退化趋势的刻画精度和早期故障预警能力;数据驱动与知识引导的双重学习框架使系统具备自主进化能力,可动态适应设备老化与工况变化,通过持续学习运维经验不断优化预测模型,为设备健康管理提供了可靠的技术支撑。

[0017] 另外,本发明构建了具有自学习能力的闭环优化系统,实现了预测模型的持续进化。系统通过对比预测结果与实际故障记录的差异,自动优化模型参数;同时从新增维修案例中提取有效的故障特征组合,不断丰富知识库内容。这种双重优化机制使系统能够适应设备老化过程中特征变化,及时识别新型故障模式。该系统突破了传统预测模型静态化的局限,实现了预测能力随使用时间的持续提升。

附图说明

[0018] 图1为本发明实施例提供的一种多源数据融合的关键部件故障预测方法流程图。

具体实施方式

[0019] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0020] 可以理解的是,基于背景技术中的缺陷,本发明实施例提出了一种多源数据融合

的关键部件故障预测方法,具体如图1所示,所述方法包括以下步骤:

S1、利用多源传感器采集清筛机关键部件数据,构建多源异构传感网络,通过预处理构建分析数据集,通过信号处理完成多维度监测数据的时空对齐与质量优化;

针对清筛机关键部件(振动筛箱、激振器、输送带驱动装置)的故障预测需求,本发明实施例构建了多物理量协同监测的多源异构传感网络。

[0021] 进一步地,构建多源异构传感网络具体包括:在振动监测方面,在筛箱侧板安装三轴ICP加速度传感器(频响0.5-10kHz,量程±50g),激振器轴承座布置声发射传感器(谐振频率150kHz);温度监测采用PT100嵌入式热电偶(激振器润滑点)和红外热像仪(输送带电机绕组);油液状态通过在线颗粒计数器(ISO4406标准)和水分传感器实时监测;同时采集液压系统压力(4-20mA压力变送器)和振动筛倾角(MEMS陀螺仪)工况参数。所有传感器信号通过工业CAN总线(ISO11898-2)传输至边缘计算节点,采用IEEE1588v2协议实现μs级时间同步。

[0022] 通过构建多源异构传感网络采集清筛机运行状态数据与历史维修台账记录,并通过预处理将采集的清筛机运行状态数据的格式对齐,构建分析数据集。所述运行状态数据包括:振动、温度、压力的传感器信号;所述预处理包括:数据清洗、去噪及格式标准化处理。预处理首先通过DBSCAN聚类算法,基于筛体倾角和液压压力工况参数自动识别设备的不同工作模式(如高速、低速),为后续信号处理提供工况分类依据;再针对不同工况动态调整振动信号的VMD模态分解数、声发射信号的小波变换参数处理方式,并统一进行温度数据的标准化和油液颗粒的分布建模,最终生成与工况匹配的128维时域、频域及时频域特征矩阵,实现多源监测数据的高质量预处理。

[0023] 具体地,所述通过预处理构建分析数据集具体包括:

首先进行工况识别,基于筛体倾角、液压压力建立工况特征向量,通过DBSCAN聚类划分典型工作模式;针对振动信号采用工况自适应的VMD去噪算法,动态确定模态分解数K=round(log2(fs/f_齿轮啮合)),筛选包含故障特征的IMF分量重构信号;声发射信号通过Morlet小波变换提取冲击特征;温度数据采用滑动窗口Z-score标准化消除环境温度影响;油液颗粒数据通过韦伯分布拟合建立污染度退化模型;

最终生成时间对齐的多维特征矩阵,包含时域(峰值因子、脉冲指标)、频域(齿轮啮合边带能量比)、时频域(小波包节点熵值)的128维特征,为后续智能诊断提供高质量输入。

[0024] 进一步地,本发明实施例还通过信号处理方法实现振动、温度、油液的多维度监测数据的时空对齐与质量优化,有效克服复杂工况下的信号干扰问题。

[0025] 具体地,通过信号处理完成多维度监测数据的时空对齐包括:

时间同步:采用IEEE 1588v2精密时钟协议,统一振动、温度、油液传感器的采样时间戳,消除因硬件延迟或采样率差异导致的数据时间错位;

空间对齐:基于部件物理位置(如振动传感器安装在齿轮箱侧壁、温度传感器嵌入轴承座),建立传感器数据的空间映射关系,确保故障信号能关联到具体部件。

[0026] 通过信号处理完成多维度监测数据的质量优化包括:

工况自适应去噪:针对振动信号,使用变分模态分解(VMD)动态调整模态参数,分离噪声与故障特征;对温度数据,通过滑动窗口Z-score标准化消除环境干扰;

多模态特征增强:结合时域(如峰值因子)、频域(如齿轮啮合边带能量)、时频域(小波包熵)特征,并通过韦伯分布建模油液颗粒数据,提升故障敏感度。

[0027] 通过上述的时空对齐和信号优化,解决传统方法因数据不同步或噪声导致的误判,使早期故障特征(如轴承微裂纹、齿轮初期磨损)的检出率显著提高。)该方案解决了清筛机变转速、强冲击工况下的信号调制问题,通过多源数据时空对齐显著提升了早期故障识别率。

[0028] S2、基于部件物理连接关系构建动态拓扑图模型,运用图神经网络量化故障传播路径与强度,形成涵盖局部状态与整体健康度的多层次特征表征,并动态调整融合权重;

本发明实施例采用图神经网络架构,将清筛机关键部件间的物理连接关系转化为拓扑图结构,实现故障传播特性的系统级建模。

[0029] 基于部件物理连接关系构建动态拓扑图模型包括:

2.1.基于设备物理连接关系构建拓扑图结构;将振动筛箱、激振器的关键部件转化为图节点,部件间的动力传递路径转化为有向连接边。通过量化连接强度的权重矩阵,反映不同部件间的故障传播能力,其中,钢制部件的连接强度高于橡胶减震部件。

[0030] 该拓扑结构支持动态调整,可适应设备改造需求。拓扑图结构模型表示如下:

$$G=(V,E,W)$$

[0031] $V=\{v_1,\ldots v_n\}$:节点集,表示各监测部件(如振动筛、激振器等)。

[0032] $E \in V \times V$:边集,表示部件间的动力传递路径。

[0033] $W \in \mathbb{R}^{n\times n}$:权重矩阵,元素 $w_{ij}=\dfrac{k}{d_{ij}^2+\varepsilon}$ 其中:

d_{ij}:部件i与j的物理距离。

[0034] k:材料传导系数。

[0035] ε:极小常数,防止分母为零。

[0036] 2.2.设计多维节点特征编码机制;每个节点特征包含时频域特征、工况参数和空间位置信息三类数据。时频域特征涵盖振动信号的峰值因子、包络熵等60个指标;工况参数包括转速、负载和温度;空间位置记录安装坐标。通过标准化处理和特征选择算法,确保输入特征的统一性和有效性。

[0037] 每个节点 v_i 的特征向量:

$$h_i=[x_i^T \| y_i^T \| z_i^T]$$

[0038] $x_i \in \mathbb{R}^6$:时频域特征(如峰值因子、包络熵等)。

[0039] $y_i \in \mathbb{R}^3$:工况特征(如转速、负载、温度)。

[0040] $z_i \in \mathbb{R}^2$:空间特征(安装位置坐标)。

[0041] ||:向量拼接操作。

[0042] 2.3.采用多头注意力机制实现特征交互;设计四组独立的注意力计算单元,每组关注不同的故障传播模式。各单元通过可训练参数计算节点间的注意力权重,动态捕捉关键故障路径。节点特征更新时保留四组输出的组合结果,使模型能同时识别局部异常和全

局传播规律。多头注意力机制表示如下：

多头注意力机制(K=4头)更新节点特征：

$$h_i' = \|_{k=1}^{K} \sigma\left(\sum_{j\in N_i} \alpha_{ij}^{k} W^{k} h_j\right)$$

[0043] α_{ij}^{k}:注意力系数,计算为:

$$\alpha_{ij}^{k} = \mathrm{softmax}\left(\frac{(W_q^k h_i)^T (W_k^k h_j)}{\sqrt{d_k}}\right)$$

[0044] $W_q^k, W_k^k \in \mathbb{R}^{d_k \times d}$:可学习参数;$d_k = d/K$:每头的特征维度;$\sigma$:激活函数(如ReLU)。

[0045] N_i:节点i的邻居集合。

[0046] 2.4.故障传播特征提取采用多层处理架构;先通过三层图卷积网络提取高阶节点特征,再分别计算全局特征、路径特征和时序特征。全局特征捕捉系统整体状态;路径特征分析历史故障传播规律;时序特征跟踪目标部件的退化轨迹。三类特征的组合形成完整的系统状态表征。

[0047] 通过工层图卷积后,系统级故障特征为:$H_{\mathrm{sys}} = \mathrm{READOUT}(\{h_i^L\}_{i=1}^{n})$

[0048] READOUT 函数包含:全局最大池化$h_{\max} = \max(h_1^L, \ldots, h_n^L)$。

[0049] 故障传播路径特征:$h_{\mathrm{path}} = \sum_{i\to j\in P} (h_i^L \odot h_j^L)$

[0050] 其中P为历史故障中最频繁的3条传播路径。

[0051] 2.5.设计智能特征融合机制;通过门控神经网络自动评估局部特征和系统特征的贡献度,动态调整融合权重。

[0052] 最终特征向量:$F = \beta \cdot H_{\mathrm{sys}} + (1-\beta)\cdot h_{\mathrm{target}}$

[0053] $\beta = \sigma(\mathrm{MLP}([h_{\mathrm{target}}; H_{\mathrm{sys}}])) \in [0,1]$:自适应权重。

[0054] 该机制基于动态拓扑图结构和图学习技术,能够准确捕捉部件间的故障关联特性,实现从局部状态到整体健康度的多层次评估,使模型能根据具体情况灵活调整特征利用策略。

[0055] S3、设计融合时空分析与记忆建模的混合预测模型,通过自适应的特征整合机制,完成对设备退化趋势的准确刻画与潜在故障的早期预警;

在本实施例中,混合预测模型通过时空图卷积网络(ST-GCN)和时间感知LSTM的双重建模实现早期预警。具体流程为:

首先,时空图卷积模块通过动态邻接矩阵实时量化部件间的故障传播强度(如轴承异常对齿轮箱的影响),捕捉故障在设备系统中的空间扩散规律;

同时,时间感知LSTM引入衰减因子强化近期故障特征的记忆权重,从而精准刻画退化趋势;

最后,通过三重注意力机制(节点重要性、时间重要性、模态重要性)自适应融合多维特征,当融合后的异常概率超过动态阈值(如振动+温度+油液协同超标)时触发预警。例如,轴承初期磨损会在振动频域边带能量和温度梯度中表现为微弱异常,但通过时空关联

分析和历史退化模式匹配,系统可在故障发展至明显阶段前(如磨损量<5%)提前报警。

[0056] 本发明实施例的融合时空分析与记忆建模的混合预测模型采用"时空图卷积-记忆增强-自适应聚合"的三阶段架构,具体实现如下:

时空图卷积模块:包括:动态邻接矩阵 $A_t \in \mathbb{R}^{n\times n}$,A_t为动态邻接矩阵,n为部件数量;

$$A_t[i,j]=\sigma(\mathrm{MLP}([h_i^t \| h_j^t \| \Delta t_{ij}]))$$

[0057] Δt_{ij} 表示为部件i到j的故障传播时延(通过互相关分析估计),σ:*Sigmoid* 激活函数;

MLP表示为多层感知机,输入维度2×128+1=2572×128+1=257,输出维度1,隐含层结构为257→64→1。

[0058] 时空图卷积运算:

$$H_{st}^t=\mathrm{ReLU}((A_t\odot M)H^tW_s+H^tW_t+b)$$

[0059] 其中,$A_t \in \mathbb{R}^{n\times n}$ 表示为动态邻接矩阵,n为部件数量;$H^t \in \mathbb{R}^{n\times 128}$ 表示为所有部件在时间t的特征矩阵;$M \in \mathbb{R}^{n\times n}$ 表示为可学习的空间掩码矩阵;$W_s, W_t \in \mathbb{R}^{d\times d'}$ 表示为空间/时间卷积权重矩阵$(d'=64)$;$b \in \mathbb{R}^{d'}$ 表示为偏置项。$\odot$ 表示为哈达玛积(逐元素相乘)。

[0060] 记忆增强模块:包括:改进的Time-AwareLSTM单元:

$$f_t=\sigma(W_f[h_{t-1} \| x_t]+U_fc_{t-1}+V_f\tau_t+b_f)$$
$$i_t=\sigma(W_i[h_{t-1} \| x_t]+U_ic_{t-1}+V_i\tau_t+b_i)$$
$$\tilde{c}_t=\tanh(W_c[h_{t-1} \| x_t]+V_c\tau_t+b_c)$$
$$c_t=f_t\odot c_{t-1}+i_t\odot\tilde{c}_t$$

[0061] $$o_t=\sigma(W_o[h_{t-1} \| x_t]+U_oc_t+V_o\tau_t+b_o)$$
$$h_t=o_t\odot\tanh(c_t)$$

[0062] 其中,$x_t \in \mathbb{R}^{64}$ 表示为时空图卷积模块的输出特征;$h_{t-1} \in \mathbb{R}^{64}$ 表示为上一时间步的隐藏状态;$b_* \in \mathbb{R}^{64}$ 表示为偏置项;$W_*, U_*, V_* \in \mathbb{R}^{64\times 64}$ 表示为权重矩阵(*代表f,i,c,o);Δt 表示为当前时间步与上一异常事件的时间间隔。

[0063] $\tau_t=\exp(-\lambda\Delta t)$:时间衰减因子,$(\lambda \in [0.01, 0.1])$。$\odot$:*Hadamard* 积(逐元素相乘)

自适应聚合模块包括:三种注意力机制:

节点重要性权重:$\alpha_i^v=\mathrm{softmax}(q_v^T\tanh(W_vh_i+b_v))$

[0064] 时间重要性权重:$\alpha_t^\tau=\mathrm{softmax}(q_\tau^T\tanh(W_\tau h_t+b_\tau))$

[0065] 模态重要性权重(振动/温度 /油液):$\alpha^m=\mathrm{softmax}(W_m[z_{\mathrm{vib}} \| z_{\mathrm{temp}} \| z_{\mathrm{oil}}]+b_m)$

[0066] 式中,$\alpha_i^v \in \mathbb{R}^n$ 表示为节点重要性权重(n为部件数量);$\alpha_t^\tau \in \mathbb{R}^T$ 表示为时间重要性权重(T=60时间步);$\alpha^m \in \mathbb{R}^3$ 表示为模态权重(振动、温度、油液);$q_v, q_\tau \in \mathbb{R}^{64}$ 表示为查询向量;$W_v, W_\tau \in \mathbb{R}^{64\times 64}$ 表示为特征变换矩阵;$z_{\mathrm{vib}}, z_{\mathrm{temp}}, z_{\mathrm{oil}} \in \mathbb{R}^{32}$ 表示为各模态的特征编码。

[0067] 最终预测函数：$\hat{y}=\sigma\left(\sum_{n}^{i=1}\sum_{T}^{t=1}\sum_{M}^{m=1}\alpha_i^v\alpha_t^\tau\alpha^m W_y h_{i,t}^m\right)$

[0068] $W_y\in\mathbb{R}^{64\times1}$表示为输出层权重矩阵；$\sigma$：Sigmoid 函数，输出故障概率$\hat{y}\in[0,1]$。

[0069] 损失函数设计，表示为：

复合损失：$L=L_{\text{pred}}+0.1L_{\text{recon}}+0.05L_{\text{contrast}}$

[0070] L_{pred}表示为二元交叉熵损失(预测 vs 真实标签)；$L_{\text{recon}}=\|H-\text{DEC}(\text{ENC}(H))\|_F^2$；ENC/DEC表示为编码器/解码器(隐含层维度128→64→128)。

[0071] L_{contrast}：对比损失(温度系数κ=0.5κ=0.5)。

[0072] 5.在线更新机制包括：

模型参数更新：$\theta_{t+1}=\theta_t-\eta(H_t+\epsilon I)^{-1}\odot g_t$

[0073] 其中，η表示为学习率；H_t表示为对角化的经验 Fisher 矩阵；g_t表示为梯度向量；$\epsilon=10^{-8}$表示为数值稳定项。

[0074] S4、结合实时预测误差与历史运维知识动态优化混合预测模型，建立数据驱动与知识引导的自学习系统，并完成混合预测模型的持续优化。

[0075] 本发明实施例提出的双重学习框架通过数据驱动和知识引导两个通道实现预测系统的持续进化。在数据驱动方面，系统建立了动态修正机制，能够自动识别工况变化、新型故障和模型退化三类问题，并分别触发特征权重调整、小样本学习和知识蒸馏等自适应优化策略。知识引导方面则构建了结构化的故障知识图谱，将专家经验和维修案例转化为可计算、可推理的数字化知识。具体实现上，通过实时监控预测误差，采用梯度分析技术动态评估特征重要性，并利用小样本学习快速适应新型故障模式。同时，知识图谱通过语义网络存储故障特征与解决方案的关联关系，并借助图神经网络实现知识检索和推理。两个通道通过特征提取、决策融合和反馈学习三个接口深度协同，不仅能适应数据分布变化，又能吸收专家经验。这种架构设计具备自主进化能力，通过持续整合实时监测数据和运维知识，不断优化预测模型。

[0076] 本发明实施例通过构建具有双重进化能力的智能自学习系统，通过"动态反馈-知识沉淀"的闭环机制实现预测模型的持续优化。数据驱动与知识引导的双重学习框架使系统具备自主进化能力，可动态适应设备老化与工况变化，通过持续学习运维经验不断优化预测模型，为设备健康管理提供了可靠的技术支撑。

[0077] 根据本发明的第二方面，提供一种多源数据融合的关键部件故障预测系统，包括：

数据采集与处理模块，用于利用多源传感器采集清筛机关键部件数据，构建多源异构传感网络，通过预处理构建分析数据集，通过信号处理完成多维度监测数据的时空对齐与质量优化；

多层次特征表征模块，用于基于部件物理连接关系构建动态拓扑图结构，运用图神经网络量化故障传播路径与强度，形成涵盖局部状态与整体健康度的多层次特征表征，并动态调整融合权重；

混合模型智能预测模块，用于设计融合时空分析与记忆建模的混合预测模型，通

过自适应的特征整合机制,完成对设备退化趋势的准确刻画与潜在故障的早期预警;

混合预测模型优化模块,结合实时预测误差与历史运维知识动态优化混合预测模型,建立数据驱动与知识引导的自学习系统,并完成混合预测模型的持续优化。

[0078] 可以理解的是,本发明提供的一种多源数据融合的关键部件故障预测系统系统与前述各实施例提供的一种多源数据融合的关键部件故障预测系统方法相对应,一种多源数据融合的关键部件故障预测系统系统的相关技术特征可参考一种多源数据融合的关键部件故障预测系统方法的相关技术特征,在此不再赘述。

[0079] 另外地,本发明实施例提供了一种电子设备,该电子设备可以包括:处理器(processor)、通信接口(Communications Interface)、存储器(memory)和通信总线,其中,处理器,通信接口,存储器通过通信总线完成相互间的通信。处理器可以调用存储器中的逻辑指令,以执行一种多源数据融合的关键部件故障预测方法的实施步骤。

[0080] 此外,上述的存储器中的逻辑指令可以通过软件功能单元的形式实现并作为独立的产品销售或使用时,可以存储在一个计算机可读取存储介质中。基于这样的理解,本发明的技术方案本质上或者说对现有技术做出贡献的部分或者该技术方案的部分可以以软件产品的形式体现出来,该计算机软件产品存储在一个存储介质中,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)执行本发明各个实施例所述方法的全部或部分步骤。而前述的存储介质包括:U盘、移动硬盘、只读存储器(ROM,Read-Only Memory)、随机存取存储器(RAM,Random Access Memory)、磁碟或者光盘等各种可以存储程序代码的介质。

[0081] 通过以上的实施方式的描述,本领域的技术人员可以清楚地了解到各实施方式可借助软件加必需的通用硬件平台的方式来实现,当然也可以通过硬件。基于这样的理解,上述技术方案本质上或者说对现有技术做出贡献的部分可以以软件产品的形式体现出来,该计算机软件产品可以存储在计算机可读存储介质中,如ROM/RAM、磁碟、光盘等,包括若干指令用以使得一台计算机设备(可以是个人计算机,服务器,或者网络设备等)执行各个实施例或者实施例的某些部分所述的方法。

[0082] 最后应说明的是:以上所述仅为本发明的优选实施例而已,并不用于限制本发明,尽管参照前述实施例对本发明进行了详细的说明,对于本领域的技术人员来说,其依然可以对前述各实施例所记载的技术方案进行修改,或者对其中部分技术特征进行等同替换,凡在本发明的精神和原则之内,所作的任何修改、等同替换、改进等,均应包含在本发明的保护范围之内。

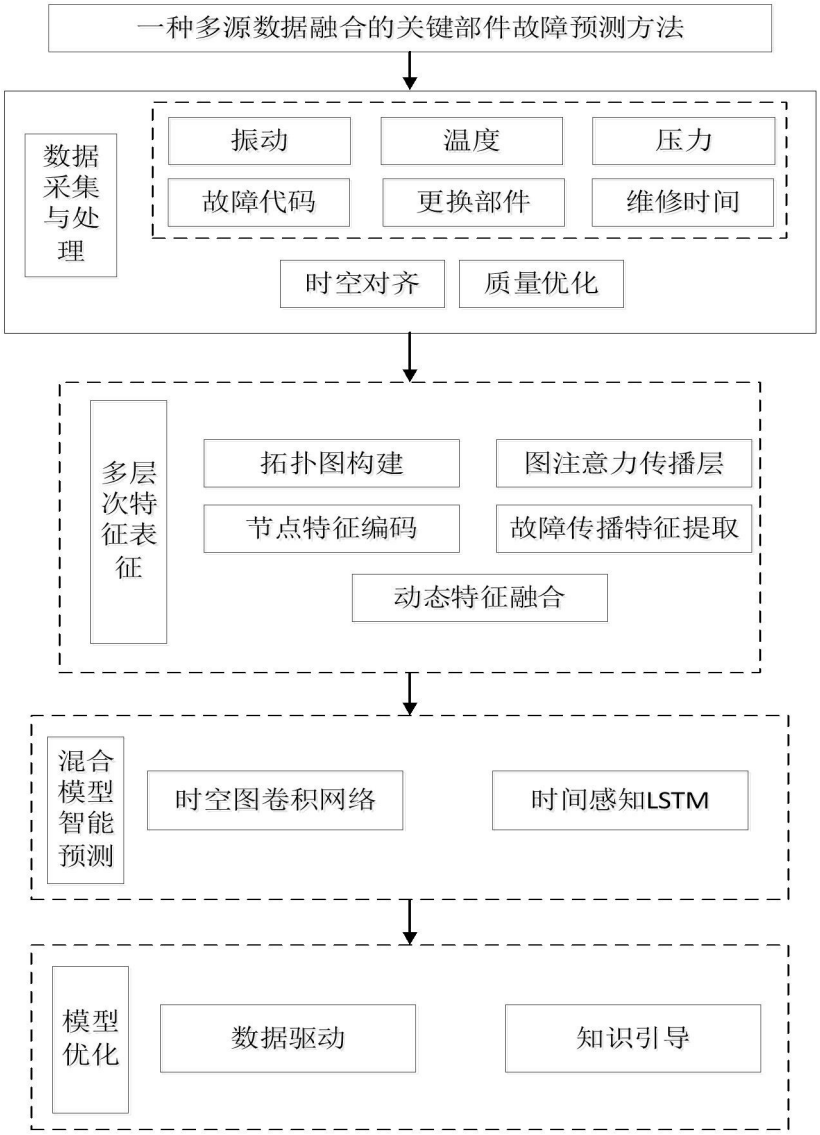
一种多源数据融合的关键部件故障预测方法
数据采集与处理
振动
温度
压力
故障代码
更换部件
维修时间
时空对齐
质量优化
多层次特征表征
拓扑图构建
图注意力传播层
节点特征编码
故障传播特征提取
动态特征融合
混合模型智能预测
时空图卷积网络
时间感知LSTM
模型优化
数据驱动
知识引导

图1