(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121036770 A
(43)申请公布日 2025.11.28

(21)申请号 202511574664.3
(22)申请日 2025.10.31
(71)申请人 长沙矿冶研究院有限责任公司
地址 410000 湖南省长沙市岳麓区麓山南路966号
(72)发明人 胡海浪 汪檠 王栋达
(74)专利代理机构 长沙朕扬知识产权代理事务所(普通合伙) 43213
专利代理师 魏巍
(51)Int.Cl.
H03M 7/30(2006.01)
G06F 18/241(2023.01)
G06F 18/10(2023.01)
G06F 18/213(2023.01)
G06F 18/25(2023.01)
G06F 18/27(2023.01)
G06N 3/0464(2023.01)
G06N 3/045(2023.01)
G06N 3/048(2023.01)
G06N 3/082(2023.01)
G06N 3/084(2023.01)
G06N 3/0985(2023.01)
G06N 3/0442(2023.01)
G06F 123/02(2023.01)

权利要求书3页 说明书12页 附图1页

(54)发明名称

多源异构时序数据的压缩、电机故障预测方法及系统

(57)摘要

本发明公开了多源异构时序数据的压缩、电机故障预测方法及系统,该压缩方法,通过多尺度特征提取、SE加权融合、混合池化及聚合器坍缩的协同作用,实现了时间序列数据的智能压缩与特征增强。该架构能够同时完成序列长度的合理缩减与特征深度的有效提升,在保留关键故障特征的前提下,解决了工业场景中多源异构传感器数据融合的技术难题,克服了传统降维方法信息损失严重的局限性。

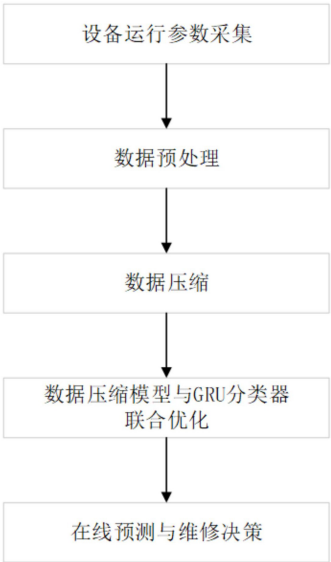

CN 121036770 A

1.一种多源异构时序数据的压缩方法,其特征在于,包括:

对预处理好的多源异构时序数据输入到训练好的数据压缩模型中,得到压缩数据;所述多源异构时序数据包括至少两种不同来源不同格式的时序数据;

所述数据压缩模型被配置为:对所述预处理好的多源异构时序数据进行多尺度特征提取,并融合提取得到的多尺度特征,得到第一融合特征序列;计算所述第一融合特征序列通道的注意力权重,并基于所述通道的注意力权重对所述第一融合特征序列进行加权融合,得到第二融合特征序列;对所述第二融合特征序列进行混合池化,得到混合池化后的特征序列;对混合池化后的特征序列执行时间维度坍缩处理,得到压缩数据。

2.根据权利要求1所述的多源异构时序数据的压缩方法,其特征在于,所述数据压缩模型包括多尺度特征提取模块,所述多尺度特征提取模块包括多个并行、且卷积核大小不一的深度卷积层、第一激活层以及特征融合层,每个深度卷积层被配置为提取对应尺度大小的特征序列,所述第一激活层被配置为将多个不同尺度的特征序列进行非线性操作,所述特征融合层用于将非线性操作后的多个不同尺度的特征序列进行拼接,得到第一融合特征序列;

和/或

所述数据压缩模型包括SE注意力模块,所述SE注意力模块包括第一平均池化层、全连接非线性变换层以及逐通道点积层,所述第一平均池化层被配置为对输入的第一融合特征序列进行平均池化处理,得到所述第一融合特征序列的每个通道的全局信息;所述全连接非线性变换层被配置为基于每个通道的全局信息计算每个通道的注意力权重;所述逐通道点积层被配置为基于每个通道的注意力权重计算对所述第一融合特征序列进行加权融合,得到第二融合特征序列;

和/或

所述数据压缩模型包括混合池化模块,所述混合池化模块包括第二平均池化层、最大池化层以及通道拼接层,所述第二平均池化层被配置为对所述第二融合特征序列进行平均池化,得到第一池化序列,所述最大池化层被配置为所述第二融合特征序列进行最大池化,得到第二池化序列;所述通道拼接层被配置为将所述第一池化序列和第二池化序列进行通道拼接,得到混合池化特征序列;

和/或

所述数据压缩模型包括聚合模块,所述聚合模块包括一维卷积层、归一化层以及第二激活层,所述一维卷积层被配置为提取混合池化特征序列的一维特征序列,所述归一化层被配置为将所述一维特征序列进行归一化,所述第二激活层被配置为对归一化后的一维特征序列再次引入非线性变换。

3.根据权利要求1所述的多源异构时序数据的压缩方法,其特征在于,所述多源异构时序数据为电机的运行数据,所述电机的运行数据包括以下任意几种的组合:

电机三相电流值、电机的振动加速度值、电机转速值、电机的功率因素值、电机轴承温度值以及电机绕组温度值。

4.根据权利要求3所述的多源异构时序数据的压缩方法,其特征在于,所述多源异构时序数据的预处理包括:

对所述多源异构时序数据进行数据清洗,数据清洗方式包括以下任意一种或几种的组

合：

方式1:采用异常值检测算法检测所述多源异构时序数据中的异常值,并进行剔除；

方式2:剔除电机启动后和/或停止后预设时间段的多源异构时序数据；

方式3:剔除电机三相电流值为0,但电机转速值不为0的多源异构时序数据；

方式4:当所述多源异构时序数据包括:电机的振动加速度值或电机转速值时,对所述电机的振动加速度值或电机转速值进行低通滤波；

所述多源异构时序数据的预处理包括:对所述多源异构时序数据进行时间对齐处理；

所述多源异构时序数据的预处理包括:对所述多源异构时序数据进行标准化或归一化处理。

5.根据权利要求1所述的多源异构时序数据的压缩方法,其特征在于,所述多源异构时序数据的预处理包括：

按预设时间步长对所述多源异构时序数据进行切片,得到多个切片时序数据段；

所述得到的多个切片时序数据段输入到训练好的数据压缩模型中,包括：

按序依次输入到所述数据压缩模型中,得到每个切片时序数据段对应的局部压缩数据,将局部压缩数据进行组装,得到最终的压缩数据。

6.一种电机故障预测方法,其特征在于,包括以下步骤：

采用权利要求1-5任意一项所述的多源异构时序数据的压缩方法,对采集的电机运行数据进行数据压缩,并将压缩后的数据输入至训练好的故障预测模型中,得到电机未来预定周期内可能发生故障的概率。

7.根据权利要求6所述的电机故障预测方法,其特征在于,所述故障预测模型为GRU分类器；

和/或

采用Adam优化算法对所述数据压缩模型和故障预测模型进行联合训练,训练损失函数为二进制交叉熵损失。

8.根据权利要求6所述的电机故障预测方法,其特征在于,采用Adam优化算法对所述数据压缩模型和故障预测模型进行联合训练,所述联合训练包括以下步骤：

获取历史电机运行数据及其对应的使用寿命,所述使用寿命为电机因故障的失效时间点;将所述历史电机运行数据进行预处理,得到多个时间切片时序数据段；

根据所述失效时间点以及每个时间切片末尾的时间节点,计算每个时间切片距离失效时间点的剩余使用寿命,并根据每个时间切片对应的剩余使用寿命确定每个时间切片的训练标签,根据每个时间切片以及所述训练标签构建训练数据,得到多个训练数据；

将多个训练数据依次输入到数据压缩模型中,得到多个压缩训练数据,并将得到的多个压缩训练数据依次输入至故障预测模型中进行训练。

9.根据权利要求6所述的电机故障预测方法,其特征在于,根据每个时间切片对应的剩余使用寿命确定每个时间切片的训练标签包括：

将所述时间切片对应的剩余使用寿命与预设的阈值进行比较,当大于预设阈值,则使用第一训练标签标注所述时间切片,当小于或等于预设阈值,则使用第二训练标签标注所述时间切片。

10.根据权利要求9所述的电机故障预测方法,其特征在于,当预测的所述电机未来预

定周期内可能发生故障的概率大于预设的第一概率阈值,发送报警信号至用户;

当预测的电机未来预定周期内可能发生故障的概率小于或等于第一概率阈值且大于预设的第二概率阈值时,加强设备状态监测。

11.一种计算机系统,包括存储器、处理器以及存储在存储器上并可在处理器上运行的计算机程序,其特征在于,所述处理器执行所述计算机程序时实现上述权利要求1至10任一所述方法的步骤。

多源异构时序数据的压缩、电机故障预测方法及系统

技术领域

[0001] 本发明涉及多源异构时序数据的压缩处理领域,具体涉及多源异构时序数据的压缩、电机故障预测方法及系统。

背景技术

[0002] 在工业设备预测性维护领域,现有技术存在三个关键性缺陷,直接制约了故障预测的准确性和实用性。

[0003] 首先,在特征提取方面,传统方法主要采用单一尺度的时域或频域分析(如FFT、小波变换),或简单的统计特征提取(如均值、方差)。这类方法难以有效处理工业场景中多源异构传感器数据(如高频振动与低频温度信号),导致关键故障特征丢失或弱化。特别是对于设备电机这类复杂工况,传统降维方法(如PCA)往往破坏时序相关性,无法兼顾序列长度压缩和特征深度保留的双重需求。

发明内容

[0004] 本发明提供了多源异构时序数据的压缩、电机故障预测方法及系统,用于解决现有的特征提取方法无法兼顾序列长度压缩和特征深度保留的双重需求的技术问题。

[0005] 为解决上述技术问题,本发明提出的技术方案为:

一种多源异构时序数据的压缩方法,包括:

对预处理好的多源异构时序数据输入到训练好的数据压缩模型中,得到压缩数据;所述多源异构时序数据包括至少两种不同来源不同格式的时序数据;

所述数据压缩模型被配置为:对所述预处理好的多源异构时序数据进行多尺度特征提取,并融合提取得到的多尺度特征,得到第一融合特征序列;计算所述第一融合特征序列通道的注意力权重,并基于所述通道的注意力权重对所述第一融合特征序列进行加权融合,得到第二融合特征序列;对所述第二融合特征序列进行混合池化,得到混合池化后的特征序列;对所述混合池化特征序列执行时间维度坍缩处理,得到压缩数据。

[0006] 优选的,所述数据压缩模型包括多尺度特征提取模块,所述多尺度特征提取模块包括多个并行、且卷积核大小不一的深度卷积层、第一激活层以及特征融合层,每个深度卷积层被配置为提取对应尺度大小的特征序列,所述第一激活层被配置为将多个不同尺度的特征序列进行非线性操作,所述特征融合层用于将非线性操作后的多个不同尺度的特征序列进行拼接,得到第一融合特征序列;

和/或

所述数据压缩模型包括SE注意力模块,所述SE注意力模块包括第一平均池化层、全连接非线性变换层以及逐通道点积层,所述第一平均池化层被配置为对输入的第一融合特征序列进行平均池化处理,得到所述第一融合特征序列的每个通道的全局信息;所述全连接非线性变换层被配置为基于每个通道的全局信息计算每个通道的注意力权重;所述逐通道点积层被配置为基于每个通道的注意力权重计算对所述第一融合特征序列进行加权

融合,得到第二融合特征序列;

和/或

所述数据压缩模型包括混合池化模块,所述混合池化模块包括第二平均池化层、最大池化层以及通道拼接层,所述第二平均池化层被配置为对所述第二融合特征序列进行平均池化,得到第一池化序列,所述最大池化层被配置为所述第二融合特征序列进行最大池化,得到第二池化序列;所述通道拼接层被配置为将所述第一池化序列和第二池化序列进行通道拼接,得到混合池化特征序列;

和/或

所述数据压缩模型包括聚合模块,所述聚合模块包括一维卷积层、归一化层以及第二激活层,所述一维卷积层被配置为提取混合池化特征序列的一维特征序列,所述归一化层被配置为将所述一维特征序列进行归一化,所述第二激活层被配置为对归一化后的一维特征序列再次引入非线性变换。

[0007] 优选的,所述多源异构时序数据为电机的运行数据,所述电机的运行数据包括以下任意几种的组合:

电机三相电流值、电机的振动加速度值、电机转速值、电机的功率因素值、电机轴承温度值以及电机绕组温度值。

[0008] 优选的,所述多源异构时序数据的预处理包括:

对所述多源异构时序数据进行数据清洗,所述数据清洗方式包括以下任意一种或几种的组合:

方式1:采用异常值检测算法检测所述多源异构时序数据中的异常值,并进行剔除;

方式2:剔除电机启动后和/或停止后预设时间段的多源异构时序数据;

方式3:剔除电机三相电流值为0,但电机转速值不为0的多源异构时序数据;

方式4:当所述多源异构时序数据包括:电机的振动加速度值或电机转速值时,对所述电机的振动加速度值或电机转速值进行低通滤波;

所述多源异构时序数据的预处理包括:对所述多源异构时序数据进行时间对齐处理;

所述多源异构时序数据的预处理包括:对所述多源异构化数据进行标准化或归一化处理。

[0009] 优选的,所述多源异构时序数据的预处理包括:

按预设时间步长对所述多源异构时序数据进行切片,得到多个切片时序数据段;

所述得到多个切片时序数据段输入到训练好的数据压缩模型中,包括:

按序依次输入到所述数据压缩模型中,得到每个切片时序数据段对应的局部压缩数据,将局部压缩数据进行组装,得到最终的压缩数据。

[0010] 一种电机故障预测方法,包括以下步骤:

采用上述的多源异构时序数据的压缩方法,对采集的电机运行数据进行数据压缩,并将压缩后的数据输入至训练好的故障预测模型中,得到电机未来预定周期内可能发生故障的概率。

[0011] 优选的,所述故障预测模型为GRU分类器;

和/或

采用Adam优化算法对所述数据压缩模型和故障预测模型进行联合训练,训练损失函数为二进制交叉熵损失。

[0012] 优选的,采用Adam优化算法对所述数据压缩模型和故障预测模型进行联合训练,所述联合训练包括以下步骤:

获取历史电机运行数据及其对应的使用寿命,所述使用寿命为电机因故障的失效时间点;将所述历史电机运行数据进行预处理,得到多个时间切片时序数据段;

根据所述失效时间点以及每个时间切片的时间节点,计算每个时间切片距离失效时间点的剩余使用寿命,并根据每个时间切片对应的剩余使用寿命确定每个时间切片的训练标签,根据每个时间切片以及所述训练标签构建训练数据,得到多个训练数据;

将多个训练数据依次输入到数据压缩模型中,得到多个压缩训练数据,并将得到的多个压缩训练数据依次输入至故障预测模型中进行训练。

[0013] 优选的,根据每个时间切片对应的剩余使用寿命确定每个时间切片的训练标签包括:

将所述时间切片对应的剩余使用寿命与预设的阈值进行比较,当大于预设阈值,则使用第一训练标签标注所述时间切片,当小于或等于预设阈值,则使用第二训练标签标注所述时间切片。

[0014] 优选的,当预测的所述电机未来预定周期内可能发生故障的概率大于预设的第一概率阈值,发送报警信号至用户;

当预测的电机未来预定周期内可能发生故障的概率小于或等于第一概率阈值且大于预设的第二概率阈值时,加强设备状态监测。

[0015] 一种计算机系统,包括存储器、处理器以及存储在存储器上并可在处理器上运行的计算机程序,所述处理器执行所述计算机程序时实现上述方法的步骤。

[0016] 本发明具有以下有益效果:

1、本发明的多源异构时序数据的压缩方法,通过多尺度特征提取、SE(通道注意力)加权融合、混合池化及聚合器坍缩的协同作用,实现了时间序列数据的智能压缩与特征增强。该架构能够同时完成序列长度的合理缩减与特征深度的有效提升,在保留关键故障特征的前提下,解决了工业场景中多源异构传感器数据融合的技术难题,克服了传统降维方法信息损失严重的局限性。

[0017] 2、在优选方案中,本发明构建了端到端的时序压缩与GRU分类器联合学习架构。该架构突破了传统分阶段处理的局限,使特征压缩模块能够根据GRU分类任务的需求动态优化特征提取策略。压缩后的高密度时序特征被输入GRU网络进行深度时序建模,有效捕捉设备状态演变的长期依赖关系。这种一体化设计不仅提升了模型对复杂故障特征的识别能力,还显著降低了对专业领域知识和人工特征工程的依赖,增强了系统的自适应能力。

[0018] 3、在优选方案中,本发明重新定义了故障预测的目标范式,将传统的剩余使用寿命回归预测转化为基于时间阈值的二分类问题。通过设定合理的经验周期阈值,系统将设备状态明确划分为"安全运行"与"即将故障"两类,并输出直观的概率评估。这种设计使得预测结果能够直接对应差异化的维护决策,包括立即检修、加强监测和正常维护三种响应等级,大幅简化了运维人员的判断流程。

[0019] 除了上面所描述的目的、特征和优点之外,本发明还有其它的目的、特征和优点。下面将参照附图,对本发明作进一步详细的说明。

附图说明

[0020] 构成本申请的一部分的附图用来提供对本发明的进一步理解,本发明的示意性实施例及其说明用于解释本发明,并不构成对本发明的不当限定。在附图中:

图1为本发明优选实施例中的电机故障预测方法的流程图。

具体实施方式

[0021] 以下结合附图对本发明的实施例进行详细说明,但是本发明可以由权利要求限定和覆盖的多种不同方式实施。

[0022] 实施例一:

如图 1所示,本发明公开了一种多源异构时序数据的压缩方法,包括:

对预处理好的多源异构时序数据输入到训练好的数据压缩模型中,得到压缩数据;所述多源异构时序数据包括至少两种不同来源不同格式的时序数据;

所述数据压缩模型被配置为:对所述预处理好的多源异构时序数据进行多尺度特征提取,并融合提取得到的多尺度特征,得到融合特征序列;计算所述第一融合特征序列通道的注意力权重,并基于所述通道的注意力权重对所述第一融合特征序列进行加权融合,得到融合特征序列;分别对所述融合特征序列进行混合池化,得到混合池化特征序列;对所述混合池化特征序列执行时间维度坍缩处理,得到压缩数据。

[0023] 另外,在本实施例中,本发明还公开了一种计算机系统,包括存储器、处理器以及存储在存储器上并可在处理器上运行的计算机程序,所述处理器执行所述计算机程序时实现上述方法的步骤。

[0024] 在本实施例中,所述多源异构的数据预处理包括以下任意几种处理方式:

数据清洗、数据对齐、归一化或者标准化。

[0025] 具体选用那一种或哪几种数据预处理方式,根据实际应用场景以及最终输出目标确定,在此不做限定。

[0026] 在本实施例中,多尺度特征提取方式可采用多分支并行结构、特征金字塔结构、空洞卷积结构、跳跃连接结构或自适应池化等方式,具体多尺度特征提取方式根据具体的应用场景以及数据特征进行确定,在此不做限定。

[0027] 在本实施例中,混合池化方式可以从最大池化、平均池化、自适应池化等池化方式中选用任意多种进行融合,具体的融合方式可以采用加权融合、通道拼接、自适应混合等方式,具体混合池化,可以根据具体的应用场景以及数据特征进行确定,在此不做限定。

[0028] 在本实施例中,时间维度坍缩处理可以采用时序池化或者聚合器等方式。

[0029] 本发明针对多源异构传感器数据融合困难的问题,突破传统特征提取方法的信息损失瓶颈,实现高保真的时序特征压缩。

[0030] 实施例二:

实施例二是实施例的拓展实施例,其与实施例一的不同之处在于,结合具体的应用场景,对多源异构时序数据的压缩方法的具体步骤进行了细化。

[0031] 在预测目标定义上,现有技术多采用剩余使用寿命(RUL)的回归预测方式。这种方式存在两个固有缺陷:一是不同设备的退化速率差异显著,固定阈值的RUL预测缺乏普适性;二是回归模型输出的剩余时间数值与运维决策难以直接对应,需要二次人工解读,增加了决策复杂度。

[0032] 在模型架构方面,传统方法通常将特征提取与故障预测割裂为独立模块(如先人工提取特征再输入分类器)。这种分阶段处理导致特征提取与最终预测目标脱节,尤其对于GRU等时序模型,单步输入特征会损失设备状态的演化信息。此外,现有端到端模型(如纯LSTM)对高维工业时序数据的处理效率低下,且缺乏对多尺度特征的针对性优化。

[0033] 为解决上述问题,本实施例结合实施例一的内容,创造性的提取出一种电机故障预测方法,用于改变现有剩余使用寿命预测模型与运维决策脱节的现状,建立直接面向维修决策的智能化预测机制;其次,克服传统分阶段处理造成的特征提取与预测目标不匹配问题,构建端到端的自适应学习框架。通过技术创新,本方案力求提升故障早期预警的准确性,简化运维决策流程,并降低系统对专业领域知识的依赖,为工业设备提供更智能、更实用的预测性维护解决方案。

[0034] 具体的,本实施例中的电机故障预测方法,包括以下步骤:

1、电机运行数据的采集

通过给设备电机安装智能电表、传感器、PT100热电阻、变频器等仪表或设备采集或计算三相电流(A相、B相、C相)、功率因素、轴承温度、振动加速度、绕组温度、转速等设备运行参数。

[0035] 2、数据预处理

21、数据清洗

采用异常值提取算法剔除数据中的异常值,具体可采用3σ准则、四分位算法、Z-score算法等,在本实施例中,结合具体的应用场景以及具体数据特征,采用使用3σ准则剔除超出均值±3倍标准差的数据,如适用于正态分布参数如三相电流、振动加速度和电机转速等;

如:设采集的时序数据为$\{x_t\}_{t=1}^{N}$,其中$x_t \in \mathbb{R}$为三相电流参数在时间t的观测值,则清洗后的数据$\tilde{x}_t$可以形式化表述为:

$$\tilde{x}_t = \{x_t |\ \mu - 3\sigma \le x_t \le \mu + 3\sigma\}$$

[0036] 其中,$\mu = \frac{1}{N}\sum_{t=1}^{N} x_t$为样本均值;$\sigma = \sqrt{\frac{1}{N}\sum_{t=1}^{N}(x_t-\mu)^2}$为样本标准差。

[0037] 之后,对振动加速度和电机转速执行同样操作。

[0038] 使用工艺约束法,对电流为0,但转速>0进行筛除;

筛除启停阶段数据,即剔除电机启动后30秒内和停止后的数据;

22、数据对齐

先确定目标时间轴,在本方案中,选择最高采样频率1秒作为基准时间轴(t=0,1,2…秒)。

[0039] 对三相电流(A相、B相、C相)的瞬时值平方后求平均再开方,计算其有效值,各从

1500个电流采样点中提取代表性值;其中三相电流有效值计算方式为:

$$I_{rms}=\sqrt{\frac{1}{1500}\sum_{i=1}^{1500}I_i^2}$$

[0040] 其中,I_i表示A相电流采样点。之后,对B相和C相电流执行同样计算。

[0041] 对振动加速度先进行低通滤波,有效保留振动信号特征并抑制高频噪声 ,滤波后信号最高频率应≤2.0 kHz,再对齐进行有效值计算,对齐方法和计算三相电流一样,即对瞬时值平方后求平均再开方,从2000个振动加速度采样点中提取代表性值;

电机转速数据对齐方法和振动加速度一致。

[0042] 23、数据归一化

将数据标准化,以便于后续算法处理。例如,将不同量纲数据转换为相同量纲,使其在模型训练时具有可比性。

[0043] 24、数据切片

对于连续时间序列的历史数据,使用步长为T的窗口对数据进行切分,所提出的方法根据时间窗口来定义数据标签。

[0044] 具体的,数据标签获取具体如下:获取历史电机运行数据及其对应的使用寿命,所述使用寿命为电机因故障的失效时间点;将所述历史电机运行数据进行预处理,得到多个时间切片时序数据段;

根据所述失效时间点以及每个时间切片末尾时刻的时间节点,计算每个时间切片距离失效时间点的剩余使用寿命:

设EOL为每次故障时确定失效时间,记RUL为剩余使用寿命,那么EOL和时间点t时的RUL存在以下数学关系:

$$RUL(t)=EOL-t$$

[0045] 根据每个时间切片对应的剩余使用寿命确定每个时间切片的训练标签,根据每个时间切片以及所述训练标签构建训练数据,得到多个训练数据;

其中,根据每个时间切片对应的剩余使用寿命确定每个时间切片的训练标签采用以下优选方案:

将所述时间切片对应的剩余使用寿命与预设的阈值进行比较,当大于预设阈值,则使用第一训练标签标注所述时间切片,当小于或等于预设阈值,则使用第二训练标签标注所述时间切片。

例如,设定时间窗口阈值为w,若某时间切片对应的剩余使用寿命$F>w$,则将其标记为D0(表示安全运行期);若$F\leqslant w$,则标记为D1(表示临近故障期)。标签以one-hot编码形式表示,如D0为[1, 0],D1为[0, 1]。

[0046] 3、数据压缩

31、构建数据压缩模型

结合电机的运行数据特征,在本实施例中,所述数据压缩模型包括多尺度特征提取模块、SE注意力模块、混合池化模块以及聚合模块;

其中,所述多尺度特征提取模块包括多个并行、且卷积核大小不一的深度卷积层、

第一激活层以及特征融合层,每个深度卷积层被配置为提取对应尺度大小的特征序列,所述第一激活层被配置为将多个不同尺度的特征序列进行非线性操作,所述特征融合层用于将非线性操作后的多个不同尺度的特征序列进行拼接,得到第一融合特征序列;

在优选方案中,深度卷积层为3个,卷积核大小分别为3、5、7,卷积核输出通道数均为32。

[0047] 所述SE注意力模块包括第一平均池化层、全连接非线性变换层以及逐通道点积层,所述第一平均池化层被配置为对输入的第一融合特征序列进行平均池化处理,得到所述第一融合特征序列的每个通道的全局信息;所述全连接非线性变换层被配置为基于每个通道的全局信息计算每个通道的注意力权重;所述逐通道点积层被配置为基于每个通道的注意力权重计算对所述第一融合特征序列进行加权融合,得到第二融合特征序列;

所述混合池化模块包括第二平均池化层、最大池化层以及通道拼接层,所述第二平均池化层被配置为对所述第二融合特征序列进行平均池化,得到第一池化序列,所述最大池化层被配置为所述第二融合特征序列进行最大池化,得到第二池化序列;所述通道拼接层被配置为将所述第一池化序列和第二池化序列进行通道拼接,得到混合池化特征序列;

所述聚合模块包括一维卷积层、归一化层以及第二激活层,所述一维卷积层被配置为提取混合池化特征序列的一维特征序列,所述归一化层被配置为将所述一维特征序列进行归一化,所述第二激活层被配置为对归一化后的一维特征序列再次引入非线性变换,以增强整个聚合模块的表达能力。

[0048] 在本实施例中,第一激活层采用ReLU激活函数,第二激活函数采用Swish激活函数。

[0049] 4、故障预测

采用LSTM的改进版本GRU来构建故障预测模型,该模型能够有效预测电机在未来某个窗口内可能发生故障的概率。数据压缩模型与故障预测模型联合优化过程如下:

41、GRU输入层处理

输入层是将压缩数据带入GRU的网络层,输入的样本集可以表示为$\{\tilde{X}, y\}$,其中y表示该窗口数据对应是否发生故障的标签信息。输入数据$\tilde{X} \in \mathbb{R}^{T\times d}$为二维格式,即[时间步长,特征数量]。这里的时间步长是指每个特征的信息能够传递给下一个特征的长度。为了对设备的故障发生周期预测值进行二进制分类,时间步长需要满足后续在线采集数据的最小长度,本方案设定的时间步长为3个周期。

[0050] 42、GRU隐藏层处理

隐藏层介于输入层和输出层之间,是模型训练和测试的核心部分。GRU单元计算过程形式化表达如下:

$$R_t = \sigma(\tilde{X}_t W_{xr} + H_{t-1} W_{hr} + b_r)$$

$$Z_t = \sigma(\tilde{X}_t W_{xz} + H_{t-1} W_{hz} + b_z)$$

$$\tilde{H}_t = \tanh(\tilde{X}_t W_{xh} + (R_t \odot H_{t-1}) W_{hh} + b_h)$$

$$H_t = Z_t \odot H_{t-1} + (1 - Z_t) \odot \tilde{H}_t$$

[0051] 其中$R_t = \sigma(\tilde{X}_t W_{xr} + H_{t-1} W_{hr} + b_r)$表示计算重置门向量，$W_{xr}$和$W_{hr}$表示可学习的权重矩阵，$b_r$表示可学习的偏置向量，$H_{t-1}$表示上一时间步隐藏状态序列，$\tilde{X}_t$表示时间窗口内时刻t的样本向量，$\sigma$表示sigmoid函数；$Z_t = \sigma(\tilde{X}_t W_{xz} + H_{t-1} W_{hz} + b_z)$表示计算更新门向量，$W_{xr}$和$W_{hr}$表示可学习的权重矩阵，$b_z$表示可学习的偏置向量；$\tilde{H}_t = \tanh(\tilde{X}_t W_{xh} + (R_t \odot H_{t-1}) W_{hh} + b_h)$表示计算候选状态序列，$W_{xh}$和$W_{hh}$表示可学习的权重矩阵，$b_h$表示可学习的偏置向量，$\odot$表示按元素相乘，$\tanh(\cdot)$表示激活函数；$H_t = Z_t \odot H_{t-1} + (1 - Z_t) \odot \tilde{H}_t$表示计算最终状态。

[0052] 43、GRU输出层处理

输出层是包含一个前馈神经网络的全连接层。在本方案中，将分类器输出定义为两个元素的向量，这些特征描述了观察结果属于两类的概率：P(D0)(F> w)，P(D1)(F≤w)。然后，在输出层中有两个单元，并使用σ激活函数。输出层提供了两个类别(D0和D1)上的概率分布，处理形式化表示为：

$$y = \sigma(W_o H_T + b_o)$$

[0053] 其中，H_T表示当前窗口最后时间步隐藏状态；W_o表示可学习权重矩阵；b_o表示可学习的偏置，y表示输出的二分类概率，即剩余寿命超过指定阈值的概率$P(D_0)$和剩余寿命不超过指定阈值的概率$P(D_1)$。

[0054] 44、损失计算及反向传播

为了联合训练数据压缩模型与GRU分类器，将目标函数的损失定义为二进制交叉熵损失，该函数专门用于解决两类别分类问题。二进制交叉熵损失数学表达式如下：

$$\mathrm{L}(y, P(D_1)) = -\left[y \cdot \log P(D_1) + (1 - y) \cdot \log(1 - P(D_1)) \right]$$

[0055] 训练中采用Adam优化算法，其是随机梯度下降算法的扩展式，具有计算效率高、内存需求小以及对大数据适用性高等优点，被广泛用于深度学习模型。

[0056] 5、在线预测与维修决策

实时采集最新传感器数据，在进行数据对齐、窗口切片和数据补全后，构建与训练时相同长度的滑动窗口；输入滑动窗口数据到GRU分类器，得到当前设备在未来目标窗口内

可能发生故障(剩余寿命小于指定窗口大小阈值)的概率P(D1);预设发生故障最大概率阈值为λ_{max},最小概率阈值为λ_{min},依据概率大小维修决策:

当P(D1)>λ_{max},则立即安排检修;

当P(D1)在[λ_{min},λ_{max}]范围内,则加强设备状态监测;

当P(D1)<λ_{min},则只需正常维护。

[0057] 实施例三

实施例三是实施例二的应用实例,具体包括:

1、设备运行参数采集

通过给球磨机主电机安装智能电表、传感器、PT100热电阻、变频器等仪表或设备采集了三相电流、功率因素、轴承温度、振动加速度、绕组温度、转速等设备运行参数。数据年限为近3年左右,数据规模达到3.5T。

[0058] 采集频率如下:

三相电流采集频率为1.5kHz,即1秒采集1500次;

功率因素采集频率为1Hz,即1秒采集1次;

轴承温度采集频率为1Hz,即1秒采集1次;

振动加速度采集频率为5kHz,即1秒采集5000次;

电机转速采集频率为5kHz,即1秒采集5000次;

绕组温度采集频率为1Hz,即1秒采集1次。

[0059] 2、数据预处理

21、数据清洗、对齐:

按实施例二中的数据清洗、对齐方式对数据进行清洗、对齐,在经过清洗和对齐之后,得到1秒一个数据点为频率的一个窗口的数据集$\mathbf{X}\in\mathbb{R}^{N\times D}$($N$表示时间步数,$D$表示特征维度),一个真实的数据点可能表示为$\{304.5,311,299,0.9,70,3.5,740,101\}$,304.5表示A相电流,311表示B相电流,299表示C相电流,A相、B相、C相电流单位均为A(安),并且是在10kV电压下;0.9表示功率因素;70表示轴承温度,单位为摄氏度;3.5表示振动加速度,单位为mm/s;740表示转速,单位为r/min;101表示绕组温度,单位为摄氏度。

[0060] 22、归一化

将不同量纲数据转换为相同量纲,使其在模型训练时具有可比性,归一化的数据将在[0,1]之间。

[0061] 23、数据切片

我们采集了在过去的生产中多次电机从启动到故障的时间区间数据(每次故障发生周期可能不同),我们记EOL为每次故障时确定失效时间,记RUL为剩余使用寿命,那么EOL和时间点t时的RUL存在以下数学关系:

$$RUL(t)=EOL-t$$

[0062] 以EOL为600个生产周期为例(每周期8小时,3周期/天),将电机从启动至故障的全生命周期数据划分为多个时间窗口,每窗口长度为3个周期(即1天)。在每个窗口结束时计

算剩余使用寿命(RUL),若RUL超过设定阈值w(例如21周期,即7天),则将该窗口标记为类别D0,表示电机在未来w周期内不发生故障;否则标记为D1,表示即将发生故障。标签采用one-hot编码:D0表示为 [1, 0],D1表示为 [0, 1],分别对应“故障”与“正常”的二分类判断。

[0063] 那么在多个电机从启动到故障的时间区间内,我们会得到多个由时间窗口数据与标签信息组成的训练单元,一个训练单元为一个时间窗口数据及对应的标签信息,记一个时间窗口数据为矩阵I_{day},标签数据记为D0或D1。

[0064] 3、数据压缩

多尺度特征融合压缩过程如下:

1)输入时间窗口数据$I_{day} \in \mathbb{R}^{86400\times 8}$,对数据进行分块处理,将其切分为1200个72×8的块,每个块$I_i \in \mathbb{R}^{72\times 8}$。

[0065] 2)使用3组并行卷积核进行卷积操作,形式化表示如下:

对于卷积核大小为3的卷积计算:

$$F_3 = \mathrm{Re}LU(I_i * W_3 + b_3)$$

[0066] 其中,$*$表示一维卷积运算,$W_3 \in \mathbb{R}^{3\times 8\times 32}$为卷积核权重,$b_3 \in \mathbb{R}^{32}$为偏置,$\mathrm{Re}LU(\cdot)$表示ReLU激活函数。

对于卷积核大小为5的卷积计算:

$$F_5 = \mathrm{Re}LU(I_i * W_5 + b_5)$$

[0067] 其中,$W_5 \in \mathbb{R}^{5\times 8\times 32}$为卷积核权重,$b_5 \in \mathbb{R}^{32}$为偏置。

对于卷积核大小为7的卷积计算:

$$F_7 = \mathrm{Re}LU(I_i * W_7 + b_7)$$

[0068] 其中,$W_7 \in \mathbb{R}^{7\times 8\times 32}$为卷积核权重,$b_7 \in \mathbb{R}^{32}$为偏置。

对三个通道特征进行拼接,形式化表示为:

$$F_{cat} = [F_3 \,||\, F_5 \,||\, F_7] \in \mathbb{R}^{72\times 96}$$

[0069] 3)经过SE注意力层进行通道加权,计算过程如下:

平均池化操作,形式化表示如下:

$$z = \frac{1}{72}\sum_{t=1}^{72} F_{\mathrm{cat}}[t,:] \in \mathbb{R}^{96}$$

[0070] 非线性变换操作,输出通道权重$s \in [0,1]^{96}$,形式化表示如下:

$$s = \sigma(W_2 \mathrm{ReLU}(W_1 z + b_1) + b_2)$$

[0071] 其中,$W_1 \in \mathbb{R}^{24\times 96}$和$W_2 \in \mathbb{R}^{96\times 24}$表示权重矩阵,$b_1 \in \mathbb{R}^{24}$和$b_2 \in \mathbb{R}^{96}$表示偏置。

[0072] 通道加权计算,形式化表达如下:

$$F_{att} = F_{cat} \odot s$$

[0073] 其中加权特征$F_{att} \in \mathbb{R}^{72\times96}$。

[0074] 4)经过多尺度池化层进行多尺度池化,过程如下:

最大池化,形式化表示如下:

$$F_{max} = \mathrm{MaxPool}(F_{att}, \mathrm{kernel} = 3) \in \mathbb{R}^{72\times96}$$

[0075] 其中$\mathrm{MaxPool}(\cdot)$表示最大池化函数。

[0076] 平均池化,形式化表示如下:

$$F_{avg} = \mathrm{AvgPool}(F_{att}, \mathrm{kernel} = 5) \in \mathbb{R}^{72\times96}$$

[0077] 其中$\mathrm{AvgPool}(\cdot)$表示平均池化函数。

[0078] 通道拼接,形式化表示如下:

$$F_{pool} = [F_{max} \| F_{avg}] \in \mathbb{R}^{72\times192}$$

[0079] 5)经过聚合器执行时间维度坍缩,过程如下:

1D卷积计算,形式化如下:

$$z_{raw} = W_{agg} \cdot \mathrm{Flatten}(F_{pool}) + b_{agg}$$

[0080] 其中1D卷积核大小为72,卷积核输出通道数为128,$\mathrm{Flatten}(\cdot)$表示展平函数,它将多为张量展平为一维向量,$W_{agg} \in \mathbb{R}^{128\times(72\times192)}$表示聚合器权重矩阵,$b_{agg} \in \mathbb{R}^{128}$表示聚合器偏置。

[0081] 执行层归一化,并使用Swish函数激活,形式化表达如下:

$$z = \mathrm{Swish}(\mathrm{LayerNorm}(z_{raw})) \in \mathbb{R}^{128}$$

[0082] 其中$\mathrm{LayerNorm}(\cdot)$表示归一化函数,$\mathrm{Swish}(\cdot)$表示Swish激活函数。

[0083] 经过上述数据压缩操作后,1200个分块就能得到$\tilde{X} \in \mathbb{R}^{1200\times128}$时间窗口数据。

[0084] 4、数据压缩模型与GRU分类器联合优化

本方案实施构建的隐藏层中,先后设置了100个和50个单元的层。另外,在每个GRU层之后应用Dropout,以减少神经网络训练数据的过拟合,从而提高网络的特征提取能力。

[0085] 本方案中,我们采集了5次电机从启动到故障的区间数据,即约3000=5×600个周期(一个周期约8小时,3000个周期约1000天)。以时间窗口大小等于1天为1个训练单元,1000天共有1000个训练单元。此外,本方案模型训练为100轮。

[0086] 在一轮训练中,使用1000个训练单元进行模型训练,1000个训练单元即1000个时间窗口数据。在1个窗口数据中,先进行数据压缩,即把86400×8的原始训练数据压缩成1200×128的高维数据。接着,再按时间步t把1200个128维的数据点依次喂给GRU分类器,实施GRU前向传播,包括计算重置门向量,计算更新门向量,计算候选状态向量,计算最终隐藏状态向量,直至到最后一个时间步。然后,再使用最终隐藏状态预测在未来7天中该设备发生故障的概率。前向传播完成之后,基于该时间窗口对应的真实标签数据与模型预测的标签数据计算损失,接着对损失求导并反向传播梯度,更新模型参数。

[0087] 在完成100轮模型训练后,我们输出最终优化模型,使用该模型可以用于后续真实环境下设备故障的在线预测。

[0088] 5、在线预测与维修决策

51、实时采集最新传感器数据,再进行数据对齐、窗口切片和数据压缩后,构建与训练时相同长度(3个周期即1天)的滑动窗口测试样本χ;

52、输入滑动窗口测试样本χ到GRU分类器,得到当前设备在未来目标窗口内可能发生故障(剩余寿命小于指定窗口大小阈值)的概率P(D1);

53、预设发生故障最大概率阈值为90%,最小概率阈值为60%,依据概率大小决定维修决策:

当发生故障概率P(D1)>90%,则立即安排检修;

当发生故障概率P(D1)在[60%,90%]范围内,则加强设备状态监测;

当发生故障概率P(D1)<60%,则只需正常维护。

[0089] 综上,本发明在设备电机故障预测领域提出了三项核心创新技术,显著提升了预测性维护的智能化水平。

[0090] 第一项创新在于设计了多尺度时序特征压缩模型,通过多尺度特征提取、SE(通道注意力)加权融合、混合池化及聚合器坍缩的协同作用,实现了时间序列数据的智能压缩与特征增强。该架构能够同时完成序列长度的合理缩减与特征深度的有效提升,在保留关键故障特征的前提下,解决了工业场景中多源异构传感器数据融合的技术难题,克服了传统降维方法信息损失严重的局限性。

[0091] 第二项创新构建了端到端的多源异构时序数据压缩与GRU联合学习架构。该架构突破了传统分阶段处理的局限,使特征压缩模块能够根据GRU分类任务的需求动态优化特征提取策略。压缩后的高密度时序特征被输入GRU网络进行深度时序建模,有效捕捉设备状态演变的长期依赖关系。这种一体化设计不仅提升了模型对复杂故障特征的识别能力,还显著降低了对专业领域知识和人工特征工程的依赖,增强了系统的自适应能力。

[0092] 第三项创新重新定义了故障预测的目标范式,将传统的剩余使用寿命回归预测转化为基于时间阈值的二分类问题。通过设定合理的经验周期阈值,系统将设备状态明确划分为"安全运行"与"即将故障"两类,并输出直观的概率评估。这种设计使得预测结果能够直接对应差异化的维护决策,包括立即检修、加强监测和正常维护三种响应等级,大幅简化了运维人员的判断流程。

[0093] 以上所述仅为本发明的优选实施例而已,并不用于限制本发明,对于本领域的技术人员来说,本发明可以有各种更改和变化。凡在本发明的精神和原则之内,所作的任何修改、等同替换、改进等,均应包含在本发明的保护范围之内。

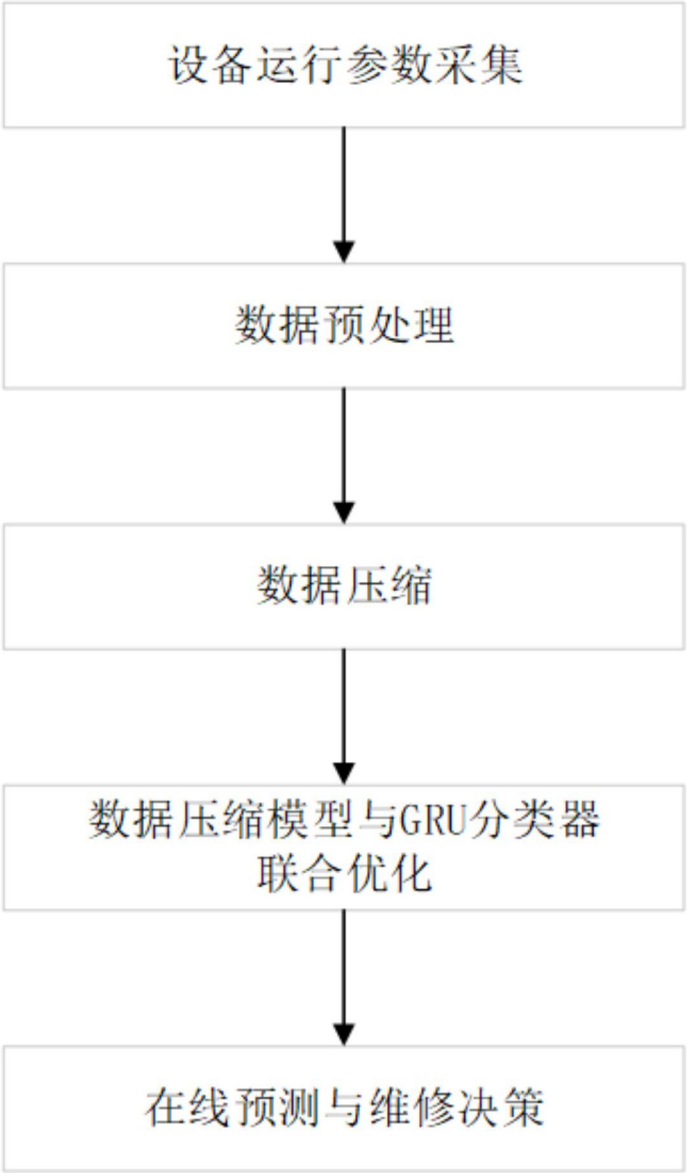

图1